


Diplomová práce



České
vysoké
učení technické
v Praze

F3

Fakulta elektrotechnická

Metódy akustickej detekcie delostreleckej strelby

Jakub Zelinka

Školitel': doc. Ing. Jakub Svatoš Ph.D.
Odbor: Počítačové inžinierstvo
Máj 2026

Podakovanie

Rád by som na tomto mieste vyjadril úprimné poďakovanie vedúcemu mojej diplomovej práce, **doc. Ing. Jakubovi Svatošovi, Ph.D.**, za jeho odborné vedenie, cenné rady a čas, ktorý mi venoval. Jeho usmernenia, trpezlivý prístup a priateľská podpora boli pre mňa pri riešení tejto problematiky neoceniteľnou pomocou.

Moja vďaka rovnako patrí **Ing. Martynovi Maxovi** za jeho ochotu a aktívnu spoluprácu, ktorou sa spoločne s nami podieľal na úspešnom vypracovaní tejto práce.

V neposlednom rade by som sa chcel zo srdca poďakovať všetkým, ktorí mi počas písania pomáhali. Mojej rodine, blízkym a priateľom patrí obrovské ďakujem za ich nekonečnú podporu, povzbudzovanie a trpezlivosť nielen pri tvorení tohto projektu, ale počas celého môjho vysokoškolského štúdia.

Prehlásenie

Prehlasujem, že som predloženú prácu vypracoval samostatne, na základe získaných poznatkov, a že som uviedol všetkú použitú literatúru.

V Prahe dňa 11.5.2026

.....

Abstrakt

Táto diplomová práca sa zaoberá problematikou akustickej detekcie a klasifikácie delostreleckej streľby s dôrazom na nasadenie v systémoch okrajovej umelej inteligencie (Edge AI). Prvá časť práce analyzuje fyzikálne princípy šírenia zvuku výstrelom a metódy detekcie paľby z ručných zbraní. Jadrom práce je návrh algoritmu na extrakciu príznakov z akustických signálov pomocou výpočtu Mel-frekvenčných keprstrálnych koeficientov (MFCC). Na spracovanie sú využité reálne nahrávky zo strelnice obsahujúce impulzné udalosti delostreleckej paľby.

Hlavným prínosom práce je návrh a natrénovanie konvolučnej neurónovej siete (CNN), ktorá bola následne optimalizovaná pre zariadenia s obmedzeným výpočtovým výkonom. Model bol podrobený celočíselnej kvantizácii a implementovaný na mikrokontrolér ESP32-S3 s využitím frameworku TensorFlow Lite Micro a hardvérových vektorových inštrukcií. Záverečná časť práce sa venuje rozsiahlej evaluácii robustnosti systému voči aditívnemu šumu.

Kľúčové slová: Akustická detekcia, Delostrelecká streľba (Artiléria), Spracovanie signálu, MFCC (Mel-frequency cepstral coefficients), Neurónové siete, Klasifikácia zvuku, Edge AI, CNN, ESP32-S3, TensorFlow Lite Micro, Kvantizácia

Školiteľ: doc. Ing. Jakub Svatoš Ph.D. Praha, ČVUT, fakulta: elektrotechnická, katedra: meraní, Technická 1902/2

Abstract

This master's thesis focuses on acoustic detection and classification of artillery fire, with an emphasis on deployment in Edge Artificial Intelligence (Edge AI) systems. The first part of the thesis analyzes the physical principles of gunshot sound propagation and the methods for detecting small arms fire. The core of the work lies in the design of an algorithm for extracting features from acoustic signals using the computation of Mel-Frequency Cepstral Coefficients (MFCC). Real-world recordings from a shooting range containing impulsive events of artillery fire are utilized for processing.

The primary contribution of this thesis is the design and training of a Convolutional Neural Network (CNN), which was subsequently optimized for devices with limited computational resources. The model was subjected to integer quantization and implemented on an ESP32-S3 microcontroller utilizing the TensorFlow Lite Micro framework and hardware vector instructions. The final part of the thesis is dedicated to a comprehensive evaluation of the system's robustness against additive noise.

Keywords: Acoustic detection, Artillery fire, Signal processing, MFCC (Mel-frequency cepstral coefficients), Neural networks, Sound classification, Edge AI, CNN, ESP32-S3, TensorFlow Lite Micro, Quantization.

Title translation: Methods of Artillery Fire Acoustic Detection

Obsah

PodĎakovanie	iii
1 Úvod	1
1.1 Motivácia	1
1.2 Formulácia problému	1
1.3 Cieľ práce	2
2 Teoretický rozbor akustických javov a metodika zberu dát	3
2.1 Zariadenie na zber dát - Akustický detektor	3
2.1.1 Senzorická časť a zber akustického signálu	4
2.1.2 Vplyv meteorologických podmienok na šírenie zvuku	5
2.1.3 Priestorová geometria a synchrónne vzorkovanie	5
2.1.4 Princíp lokalizácie metódou TDOA	5
2.1.5 Detekčný algoritmus a paralelné spracovanie	5
2.2 Charakteristika nameraných dát	6
2.2.1 Fyzikálny charakter výstrelu	7
3 Súčasný stav riešenej problematiky	9
3.1 Metódy extrakcie príznakov	9
3.2 Špecifiká akustickej detekcie delostrelectva	10
3.3 Klasifikačné algoritmy	11
3.4 Vstavané systémy pre akustický monitoring	12
4 Spracovanie signálu a extrakcia príznakov	13
4.1 Detekcia impulzu a časová segmentácia	13
4.2 Krátkodobá Fourierova transformácia (STFT)	14
4.2.1 Rámcovanie (Framing) a okienkovanie	14
4.2.2 Výpočet výkonového spektra	15
4.2.3 Výpočet magnitúdového spektra	15
4.3 Melova filtračná banka a logaritmovanie	16
4.3.1 Transformácia na Melovu škálu	16
4.3.2 Konštrukcia filtračnej banky	16
4.3.3 Filtrácia a integrácia energie	17
4.3.4 Logaritmická transformácia (dB)	17
4.4 Diskrétna kosínová transformácia (DCT)	18
5 Konvolučná Neurónová sieť - CNN	19
5.1 Príprava a formátovanie vstupných dát	19
5.2 Návrh architektúry a topológie CNN	21
5.2.1 Prvý konvolučný blok	21
5.2.2 Druhý konvolučný blok	22
5.2.3 Klasifikačná časť: Sploštenie a plne prepojené vrstvy	24
6 Trénovanie, evaluácia a porovnanie	27
6.1 Trénovanie a evaluácia základného modelu	27
6.1.1 Počiatočné výsledky a indikácia pretrénovania	27
6.1.2 Záťažový test (Stress Test) a analýza robustnosti	28
6.2 Zvýšenie robustnosti: Augmentácia dát	29
6.3 Trénovanie a evaluácia augmentovaných dát	30
6.3.1 Priebeh učenia a parametre siete	30
6.3.2 Stress test na augmentovaných dátach	31
6.3.3 Pretrénovanie na zašumených dátach	31
6.4 Porovnanie a zhodnotenie výsledkov	32
6.5 Zväčšenie súboru dát typu „non-gunshot“	33
6.5.1 Problém s nevyváženým datasetom	33
6.5.2 Matica zámien (Confusion Matrix)	33
6.6 Evaluácia robustnosti na augmentovanom datasete pri použití váh	35
6.6.1 Priebeh testovania pre jednotlivé váhové pomery	36

6.6.2 Zhodnotenie experimentu a analýza vplyvu váh	37
7 Implementácia modelu na mikrokontrolér ESP32-S3	39
7.1 Popis použitého embedded zariadenia	39
7.2 Konverzia a kvantizácia modelu	40
7.3 Vývojové prostredie a AI akcelerácia	40
7.4 Verifikácia modelu a komunikácia cez rozhranie UART	41
7.4.1 Motivácia a protokol komunikácie	41
7.4.2 Dátový balík a spracovanie na strane ESP32-S3	42
7.5 Zašumenie dát a evaluácia na zariadení ESP32-S3	42
7.5.1 Zhodnotenie testovania a porovnanie s PC.....	43
8 Validácia systému na zašumených audio vzorkách	45
8.1 Matematický model zašumenia a výpočet SNR	45
8.2 Realizácia experimentu	46
8.3 Zhodnotenie testovania a porovnanie PC vs. ESP32-S3	48
8.4 Verifikácia vplyvu kvantizácie (int8) na PC	50
Zhodnotenie vplyvu kvantizácie...	50
9 Diskusia	51
9.1 Obmedzenia navrhnutého riešenia	52
9.2 Možnosti ďalšieho rozvoja	52
10 Záver	53
Literatúra	55
Zoznam použitých skratiek	59

Obrázky

2.1 Prenosný akustický detektor[5] ..	3	6.6 Závislosť Matthewsovho korelačného koeficientu od úrovne šumu pre rôzne nastavenia váh tried.	38
2.2 Blokový diagram jednotky acustického systému[3]	4	7.1 Embedded zariadenie ESP32-S3-DEVKIT.	39
2.3 Extrahovaná jedná impulzná udalosť veľkosti 30 000 vzorkov	6	7.2 Porovnanie Matthewsovho korelačného koeficientu PC vs ESP32.	43
2.4 Zobrazenie rázovej vlny a ústovej vlny výstrelu (vo všeobecnosti).[9] ..	7	8.1 Porovnanie Matthewsovho korelačného koeficientu PC vs ESP32.	49
3.1 Gamaton frekvenčná banka filtrov	10	8.2 Porovnanie Matthewsovho korelačného koeficientu na PC pre nekvantizovaný a kvantizovaný model.	50
3.2 Akustický a seismický spektrogram[13]	11		
4.1 Výsek signálu okolo detekovanej špičky - približne 1300 vzoriek	13		
4.2 Samostatný rámec signálu po aplikovaní Hammingovho okna ...	14		
4.3 Výkonové spektrum prvého framu signálu	15		
4.4 Magnitúdove spektrum prvého rámca signálu	15		
4.5 Melova banka filtrov	16		
4.6 Melová filtračná banka energií pre jednotlivý rámec	17		
4.7 Mel frekvenčné kepstrálne koeficienty jedného rámca	18		
5.1 Formát uložených dát kepstrálnych koeficientov impulzných udalostí ..	19		
5.2 Topológia a architektúra konvolučnej neuronovej siete	21		
5.3 Prvá konvolučná vrstva	22		
5.4 Druhá konvolučná vrstva	23		
5.5 Klasifikačné vrstvy	24		
6.1 Úspešnosť na trénovacej a validačnej vzorke	27		
6.2 Bloková schéma procesu augmentácie dát v kepstrálnej oblasti.	29		
6.3 Úspešnosť na trénovacej a validačnej vzorke augmentovaných dát.	30		
6.4 Priebeh evaluácie pri 500 epochách na augmentovaných dátach.	31		
6.5 Príklad matice zámien pri evaluácii	33		

Tabuľky

6.1 Výsledok klasifikácie pre zašumené dáta (reálne podmienky).	28
6.2 Výsledok klasifikácie augmentovaných dát pri šume.	31
6.3 Porovnanie úspešnosti klasifikácie pre pôvodné/augmentované dáta. .	32
6.4 Význam základných klasifikačných metrík odvodených z matice zámien.	35
6.5 Výsledky evaluácie pre váhový pomer 1:1.	36
6.6 Výsledky evaluácie pre váhový pomer 1:2.	36
6.7 Výsledky evaluácie pre váhový pomer 1:3.	36
6.8 Výsledky evaluácie pre váhový pomer 1:4.	36
7.1 Výsledky evaluácie na zariadení ESP32-S3 pre rôzne úrovne šumu.	42
8.1 Výsledky evaluácie na PC pre dáta zašumené v časovej oblasti (.wav).	47
8.2 Výsledky evaluácie na ESP32-S3 pre dáta zašumené v časovej oblasti (.wav).	47
8.3 Výsledky evaluácie na PC pre dáta zašumené v časovej oblasti (.wav) a kvantizované na int8.	50

Kapitola 1

Úvod

1.1 Motivácia

V kontexte moderných vojenských konfliktov predstavuje delostrelecká paľba jedno z najväčších ohrození nielen pre vojenské jednotky, ale aj pre civilné obyvateľstvo. Schopnosť včas a presne detekovať prítomnosť delostreleckej aktivity je absolútne kľúčovým faktorom pre systémy včasného varovania (Early Warning Systems). Získané sekundy medzi výstrelom a dopadom projektilu môžu zachrániť ľudské životy tým, že umožnia civilistom včasné presunutie do krytov.

Tradičné radarové systémy na detekciu paľby sú síce presné, avšak ide o aktívne systémy, ktoré vyžarujú elektromagnetické vlnenie [1], čím okamžite prezrádzajú svoju pozíciu nepriateľovi. Navyše sú mimoriadne nákladné na prevádzku [2]. Z tohto dôvodu rastie dôležitosť akustických detekčných systémov. Tieto systémy sú plne pasívne, relatívne lacné na výrobu a umožňujú vytvorenie hustej senzorovej siete [3]. Aby však mohla byť takáto sieť v praxi plošne nasadená na ochranu miest a civilných zón, musí fungovať nielen na výkonných počítačoch, ale aj na malých, prenosných a energeticky nenáročných zariadeniach (*embedded systémoch*). Táto skutočnosť bola hlavnou motiváciou pre hľadanie prieniku medzi modernými metódami hlbokého učenia a obmedzeným výpočtovým hardvérom.

1.2 Formulácia problému

Akustická detekcia delostreleckej streľby predstavuje problém z dvoch hlavných dôvodov. Prvým problémom je variabilita environmentálneho šumu [3]. Akustický detektor musí vedieť spoľahlivo izolovať rázovú a ústovú vlnu výstrelu od bežných ruchov, akými sú vietor, dážď, ozveny (*echá*) v mestskej zástavbe, či iné impulzné zvuky (napríklad tresknutie dverí alebo úder do kovu), a to pri zachovaní minimálnej miery falošných poplachov (*False Positives*).

Druhý, nemenej dôležitý problém, spočíva v implementácii detekčných algoritmov. Moderné metódy, využívajúce extrakciu kepstrálnych koeficientov (MFCC) a konvolučné neurónové siete (CNN) [4], poskytujú vysokú presnosť, avšak vyžadujú značný výpočtový výkon a kapacitu pamäte. To je problém pre embedded zariadenie, na ktorom tiež bude implementovaný algoritmus rozpoznávania delostreleckej strelby.

1.3 Cieľ práce

Na základe motivácie a identifikovaných problémov je hlavným cieľom tejto diplomovej práce návrh a implementácia systému pre akustickú detekciu delostreleckej palby, ako pre počítač, tak aj pre embedded zariadenie s menším výpočtovým výkonom a pamäťou. Pre naplnenie tohto cieľa boli stanovené nasledujúce podúlohy, ktoré treba vyriešiť:

1. **Teoretická rešerš a analýza:** Vykonať rešerš existujúcich metód akustickej detekcie strelby so zameraním na delostrelectvo. Analyzovať fyzikálne a akustické charakteristiky výstrelův.
2. **Spracovanie signálu a extrakcia príznakov:** Navrhnuť a naprogramovať algoritmus na predspracovanie surových akustických nahrávok. Implementovať matematický aparát pre transformáciu signálu z časovej do kepstrálnej oblasti za účelom získania kompaktných Mel-frekvenčných kepstrálnych koeficientov (MFCC).
3. **Návrh a trénovanie neurónovej siete:** Na základe extrahovaných príznakov (MFCC) navrhnuť topológiu konvolučnej neurónovej siete (CNN). Implementovať metódy pre zvýšenie robustnosti klasifikátora, natrénovať model na experimentálnych dátach a eliminovať riziko pretrénovania.
4. **Implementácia a optimalizácia pre embedded platformu:** Modifikovať navrhnuté riešenie do dvoch funkčných variantov. Prvý variant optimalizovať pre štandardnú počítačovú platformu a druhý variant pre embedded zariadenie s obmedzenými výpočtovými a pamäťovými prostriedkami.
5. **Porovnanie a vyhodnotenie výsledkov:** Otestovať navrhnuté riešenia na reálnych dátach. Popísať rozdiely v návrhu a vykonať porovnanie oboch platforiem (PC vs. Embedded) z hľadiska celkovej presnosti detekcie a výpočtovej náročnosti.

Kapitola 2

Teoretický rozbor akustických javov a metodika zberu dát

2.1 Zariadenie na zber dát - Akustický detektor

Pre potreby tejto práce bolo využité špecializované meracie zariadenie určené na zachytávanie akustických prejavov delostreleckej palby. Zariadenie je navrhnuté ako prenosná meracia stanica umožňujúca operatívne nasadenie v poľných podmienkach[4].




Obrázok 2.1: Prenosný akustický detektor[5]

Aby zariadenie spĺňalo prísne požiadavky na detekciu rýchlych impulzných javov, je jeho hardvérová a softvérová architektúra rozdelená do niekoľkých logických celkov:

2.1.1 Senzorická časť a zber akustického signálu

Samotný mikrofón slúži ako menič akustického tlaku na elektrický signál. Pri poľných meraniach impulzných javov je kritickým faktorom dynamický rozsah a vzorkovacia frekvencia. Zariadenia štandardne využívajú analógovo-digitálne prevodníky (ADC) s vysokým, 16-bitovým až 24-bitovým rozlíšením. Zvuková vlna je pred digitalizáciou zosilnená nízkoenergetickým operačným zosilňovačom. Hoci sa pri bežnom spracovaní audia často využíva vzorkovacia frekvencia okolo 44 kHz, pre vnorené (embedded) zariadenia je to zbytočne vysoká a výpočtovo náročná hodnota. Pre spoľahlivú akustickú detekciu delostreleckej streľby plne postačuje vzorkovanie v rozsahu 16 až 24 kHz (v experimentálnej časti tejto práce bolo konkrétne využitých 22 050 Hz).[3]



Obrázok 2.2: Blokový diagram jednotky acustického systému[3]

Zásadnou prekážkou pri zbere akustických dát v exteriéri je **environmen-tálny šum**, najmä vplyv vetra. Turbulentné prúdenie vzduchu vytvára nízkofrekvenčný šum, ktorý môže prekryť užitočný signál. Na zmiernenie tohto javu sa na senzorech aplikujú rôzne techniky priestorového priemerovania, napríklad použitím poréznych materiálov (špeciálne hadice alebo protiveterné kryty), ktoré fyzikálne tlmia vplyv vzdušných vírov bez výraznej straty samotnej akustickej energie výstrelu.[3]

2.1.2 Vplyv meteorologických podmienok na šírenie zvuku

Tvar a charakteristika zaznamenananej akustickej vlny (N-vlna výstrelu a rázová vlna) výrazne závisí od prostredia. Rýchlosť šírenia zvuku v atmosfére nie je konštantná, ale je dominantne ovplyvnená aktuálnou teplotou a vektorom rýchlosti vetra. Z tohto dôvodu sú profesionálne akustické detektory vybavené dodatočnými meteorologickými senzormi pre meranie teploty, vlhkosti a atmosférického tlaku. Tieto dáta sú nevyhnutné pre presnú korekciu výpočtov pri lokalizácii, keďže prechod zvuku rôznymi teplotnými vrstvami spôsobuje refrakciu (ohyb) a ohyb zvukových vln.[3]

2.1.3 Priestorová geometria a synchronné vzorkovanie

Zariadenie využíva pole štyroch kalibrovaných mikrofónov (4-mic array).[1] Tieto mikrofóny sú mechanicky uchytené na ramenách statívu v presne definovanej priestorovej geometrii (spravidla tvoriacej trojuholníkovú základňu s jedným vyvýšeným stredovým mikrofónom). Táto známa vzdialenosť a poloha senzorov sa používa pre výpočet smeru, z ktorého zvuk prichádza. Hoci priestorové rozloženie mikrofónov predstavuje výborný potenciál pre prirodzené zväčšenie trénovacieho datasetu (keďže každý mikrofón v poli zachytáva signál s odlišnými lokálnymi odrazmi a miernym fázovým posunom), určovanie smeru prichádzajúceho zvuku nebolo primárnym cieľom tejto práce. Z dôvodu zamerania sa na samotný návrh, kvantizáciu a optimalizáciu klasifikačného modelu pre platformu Edge AI bol v experimentoch využitý záznam iba z jedného referenčného mikrofónu.

2.1.4 Princíp lokalizácie metódou TDOA

Na určenie smeru streľby (azimutu a elevačného uhla) využíva zariadenie matematickú metódu TDOA (Time Difference of Arrival), teda meranie časového rozdielu príchodu signálu. Keďže rýchlosť šírenia zvuku vo vzduchu je konečná, akustická vlna z výstrelu dorazí ku každému zo štyroch mikrofónov v mierne odlišnom čase.[6]

2.1.5 Detekčný algoritmus a paralelné spracovanie

V poľných podmienkach je akustický senzor neustále vystavený environmentálnemu šumu. Aby sa zabránilo zahŕtaniu pamäte, zariadenie nezaznamenáva zvuk kontinuálne, ale využíva takzvaný spúšťač mechanizmu (Trigger).[7]

Dáta z mikrofónov sú nepretržite ukladané do kruhového zásobníka (Circular Buffer) a súbežne analyzované v štyroch paralelných výpočtových vláknoch (pre každý mikrofón jedno vlákno).[7] Algoritmus je navrhnutý tak, aby kontinuálne vyhodnocoval úroveň pozadia a dynamicky prispôboval detekčný prah (podobne ako systémy CFAR - Constant False Alarm Rate). Akonáhle algoritmus identifikuje prudkú špičku (Peak) – definovanú ako nárast akustickej energie s prevýšením minimálne 5 dB nad aktuálnou hladinou okolitého šumu - systém vyhodnotí túto udalosť ako potenciálny výstrel.[2]


Hoci finálne cieľové zariadenie v ostrej prevádzke funguje na princípe dynamického spúšťača (Trigger) a kruhového zásobníka, pre potreby vývoja klasifikačného modelu a extrakcie príznakov v tejto práci bola poskytnutá súvislá surová audionahrávka z merania na strelnici.

2.2 Charakteristika nameraných dát

Základom pre následné spracovanie a tréňovanie klasifikačných modelov je databáza reálnych akustických nahrávok získaných počas meraní na strelnici. Tieto dáta reprezentujú autentické podmienky s prítomnosťou okolitého šumu a odrazov od terénu.

Kvantitatívne parametre databázy:

- **Rozsah súboru:** Celkovo bolo spracovaných a do databázy zaradených približne 70 unikátnych impulzných udalostí, ktoré zodpovedajú jednotlivým výstrelom delostrelectva.
- **Kategória non-gunshot:** Databáza bola rozšírená o súbor negatívnych vzoriek, ktoré majú podobný impulzný charakter ako výstrel, no pochádzajú z iných zdrojov. Medzi tieto udalosti patrí napríklad tresknutie dvermi, ľudský výkrik alebo zvuk zvona. Tieto vzorky sú kľúčové pre potlačenie falošných detekcií v reálnej prevádzke.
- **Dĺžka segmentu:** Každá zachytená udalosť je z pôvodnej surovej nahrávky extrahovaná ako časový výsek s fixnou dĺžkou 30 000 vzoriek. Keďže surové dáta z merania boli zaznamenané so vzorkovacou frekvenciou 44,1 kHz, tento extrahovaný segment predstavuje časové okno o dĺžke približne 0,68 sekundy. Aby sa znížila výpočtová náročnosť pre embedded zariadenie, bol tento signál neskôr softvérovo prevzorkovaný na frekvenciu 22 050 Hz (downsampling).




Obrázok 2.3: Extrahovaná jedna impulzná udalosť veľkosti 30 000 vzorkov

2.2.1 Fyzikálny charakter výstrelu

Pre správny návrh hardvéru a softvéru akustického detektora je nevyhnutné porozumieť fyzikálnym javom, ktoré pri výstrele vznikajú. Akustický podpis výstrelu môže byť teoreticky tvorený dvoma nezávislými zložkami, pričom ich reálna prítomnosť v nameranom signáli závisí od typu zbrane a priestorovej geometrie merania[8]:

1. **Rázová vlna (Shockwave):** Akustický tresk generovaný projektilom pri nadzvukovej rýchlosti, charakteristický strmým nárastom tlaku a vysokofrekvenčným spektrom.
2. **Ústová vlna (Muzzle Blast):** Nízko-frekvenčný impulz vznikajúci expanziou plynov pri ústí hlavne, ktorý nesie dominantnú časť energie signálu.

V kontexte experimentálnych dát spracovávaných v tejto práci boli merania akustických prejavov realizované kanónovej húfnici (DANA). Z analýzy nameraných dát vyplýva, že dominantnú a v podstate jedinou detekovateľnú zložku signálu tvorí ústová vlna, zatiaľ čo rázová vlna absentuje.



Obrázok 2.4: Zobrazenie rázovej vlny a ústovej vlny výstrelu (vo všeobecnosti).[9]

Kapitola 3

Súčasný stav riešenej problematiky

V súčasnosti existuje už niekoľko spôsobov na extrakciu príznakov s cieľom získať rozpoznávacího algoritmu. V tejto kapitole budú popísané spôsoby, ktorými sa riešia podobné problémy pri rozpoznávaní zvuku.

3.1 Metódy extrakcie príznakov


Základným predpokladom úspešnej klasifikácie akustických udalostí je voľba vhodného algoritmu na extrakciu príznakov. Hoci teoreticky možno výstrel z palnej zbrane považovať za takmer ideálny impulzný signál, v reálnom prostredí je jeho typický akustický profil (ústová vlna) výrazne deformovaný [10]. K týmto deformáciám dochádza v dôsledku disperzie šírenia zvuku v atmosfére a prítomnosti mnohonásobných odrazov v husto zastavaných alebo zalesnených oblastiach [11].

V dôsledku spomínaných deformácií signálu je nepostačujúce spoliehať sa na jednoduchú analýzu v časovej oblasti (napríklad obyčajné prahovanie amplitúdy), čo si vyžaduje nasadenie pokročilých metód číslicového spracovania. Na základe prieskumu doterajších aplikovaných riešení v oblasti detekcie zvuku sa ako najvhodnejší prístup javí extrakcia Mel-frekvenčných kepstrálnych koeficientov (MFCC). Táto metóda efektívne kombinuje diskretnú Fourierovu transformáciu (FFT), banku Mel-filtrov a výkonové spektrum [3].

Existujú aj iné metódy spracovania, ako napríklad lineárne prediktívne kepstrálne koeficienty (LPCC), ktoré využívajú autokorelačnú analýzu. Tie sú však primárne optimalizované pre aplikácie rozpoznávania ľudskej reči a identifikácie hovoriaceho, a preto sú na modelovanie impulzných udalostí menej vhodné [12].

Ďalšou alternatívou pre klasifikáciu iných než rečových signálov sú Gammatonové frekvenčné kepstrálne koeficienty (GFCC). Tie fungujú na podobnom princípe ako MFCC, avšak namiesto trojuholníkových filtrov využívajú Gammatonové filtre, ktoré ešte presnejšie modelujú fyziológiu ľudského sluchu. Napriek ich potenciálnej robustnosti v zašumenom prostredí bolo pre túto prácu zvolené MFCC, a to z dôvodu jeho signifikantne nižšej výpočtovej ná-

ročnosti, čo je kritickým parametrom pre úspešnú implementáciu na *embedded* (Edge AI) zariadeniach.[13]



Obrázok 3.1: Gamaton frekvenčná banka filtrov


3.2 Špecifiká akustickej detekcie delostrelectva

Detekcia a lokalizácia delostrelectva na bojisku predstavuje v porovnaní s detekciou ručných zbraní v mestskom prostredí špecifickú výzvu. Hlavný rozdiel spočíva v energetickom obsahu signálu a v dominantných frekvenčných pásmach, ktoré sa využívajú na detekciu na veľké vzdialenosti.

Význam infrazvukového pásma a počuteľného spektra

Kľúčovým prínosom moderného vojenského výskumu je zameranie sa na infrazvukovú oblasť (frekvencie pod 20 Hz). Infrazvukové vlny podliehajú výrazne nižšiemu atmosférickému útlmu než vlny v počuteľnom spektre. To umožňuje strategickú detekciu húfníc a mínometov na vzdialenosti presahujúce 30 km [14]. Taktiež dokážu prenikať atmosférickými tieňovými zónami.

Na druhej strane, detekcia v infrazvukovom pásme si vyžaduje rozmerné špecializované mikrofóny a je extrémne náchylná na nízko-frekvenčný hluk vetra, čo komplikuje nasadenie malých a lacných senzorov.



Obrázok 3.2: Akustický a seismický spektrogram[13]

3.3 Klasifikačné algoritmy

Neurónové siete využívané na klasifikáciu si získali pozornosť v oblasti spracovania signálov v troch hlavných historických vlnách:

1. **Algoritmus Perceptron:** Prvotné modely inšpirované biologickými neurónmi [15].
2. **Algoritmus spätnej propagácie (Backpropagation):** Zavedenie efektívneho učenia viacvrstvových sietí [16].
3. **Hlboké učenie (Deep Learning):** Moderná éra reprezentovaná úspechmi v rozpoznávaní reči a obrazu [17] pomocou konvolučných neurónových sietí (CNN).

Hoci mnohé metódy hlbokého učenia boli prevzaté z oblasti spracovania obrazu, medzi týmito doménami existujú dôležité rozdiely, ktoré opodstatňujú špecifický prístup k spracovaniu audia. Surové zvukové vzorky tvoria jednorozmerný signál v časovej oblasti, čo je fundamentálne odlišné od dvojrozmerných obrazov. Zvukové signály sa pre účely spracovania bežne transformujú do dvojrozmerných časovo-frekvenčných reprezentácií (napr. spektrogramy), avšak tieto dve osi (čas a frekvencia) nie sú homogénne tak, ako je to v prípade horizontálnej a vertikálnej osi pri obrazoch [18].

Okrem historického vývoja neurónových sietí sa v oblasti klasifikácie akustických signálov dlhodobo presadzovali aj tradičné algoritmy strojového učenia. Medzi najvýznamnejšie patria:

- **Support Vector Machines (SVM) a logistická regresia:** Metódy založené na hľadaní optimálnej rozhodovacej nadroviny, ktoré sú efektívne pri binárnej klasifikácii.[4]
- **GMM-HMM (Gaussian Mixture Models a Hidden Markov Models):** Tradičný štandard pre modelovanie štatistických vlastností a časovej následnosti akustických stavov. Hoci bol tento prístup pôvodne dominantný v rozpoznávaní reči, jeho architektúra sa ukázala ako vysoko účinná aj pri detekcii a klasifikácii komplexných environmentálnych zvukov a akustických javov v reálnom prostredí [19].

Hoci tieto metódy vyžadujú menej výpočtových zdrojov, moderný výskum sa v poslednom desaťročí prikláňa k hlbokému učeniu (**Deep Learning**), ktoré dokáže automaticky extrahovať hierarchické príznaky priamo z dát.

3.4 Vstavané systémy pre akustický monitoring

V poslednom desaťročí prešli systémy akustickej detekcie výrazným vývojom z hľadiska hardvérovej implementácie. V oblasti detekcie streľby boli publikované práce využívajúce platformy ako Raspberry Pi v kombinácii s klasickými algoritmami strojového učenia [20]. Zariadenia tohto typu však pre svoj nepretržitý chod vyžadujú inštaláciu prídavných systémov na obnovu energie (napríklad solárnych panelov), čo značne komplikuje a predražuje ich skryté nasadenie v teréne oproti nízkoenergetickým mikrokontrolérom.

Túto energetickú náročnosť je možné radikálne znížiť implementáciou systému priamo na *embedded* (vstavané) zariadenia, akými sú mikrokontroléry bez plnohodnotného operačného systému. V takomto prípade je však kritickým faktorom striktno obmedzená operačná pamäť (SRAM) mikrokontroléra, čo pre nasadenie umelej inteligencie vyžaduje použitie techník kompresie modelu.

Ako potvrdzujú moderné výskumy, pomocou techník okrajových výpočtov (Edge AI) a celočíselnej kvantizácie je dnes už možné vtesnať hlboké konvolučné siete pre klasifikáciu environmentálneho hluku do mikrokontrolérov s pamäťou len na úrovni desiatok kilobajtov.

Kapitola 4


Spracovanie signálu a extrakcia príznakov

Cieľom spracovania signálu je redukcia dimenzionality vstupných dát pri zachovaní kľúčových informácií o frekvenčnom zložení akustickej udalosti. Pre klasifikáciu delostreleckej strelby bola zvolená metóda extrakcie kepstrálnych koeficientov na Melovej škále (MFCC – Mel-Frequency Cepstral Coefficients), ktoré dobre reprezentujú spektrálnu obálku impulzných zvukov.[4]

4.1 Detekcia impulzu a časová segmentácia

Vzhľadom na to, že pôvodné nahrávky majú dĺžku 30 000 vzoriek, je pre presnú analýzu potrebné identifikovať presný moment výstrelu.

- **Detekcia špičky (Peak Detection):** Algoritmus vyhľadáva maximum amplitúdy v úvodných 20% záznamu, čo minimalizuje riziko zachytenia neskorších odrazov (echo) ako hlavnej udalosti.
- **Asymetrické okno:** Pre následnú analýzu sa extrahuje segment s dĺžkou 60 ms.[4] Okno je okolo detekovanej špičky rozložené asymetricky: 40% pred špičkou (nábeh rázovej vlny) a 60% po špičke (doznievanie a ústová vlna). Pri vzorkovacej frekvencii 22 050 Hz to predstavuje segment o dĺžke 1323 vzoriek.



Obrázok 4.1: Výsek signálu okolo detekovanej špičky - približne 1300 vzoriek

4.2 Krátkodobá Fourierova transformácia (STFT)

Proces extrakcie príznačkov prebieha v niekoľkých krokoch.[3]

4.2.1 Rámčovanie (Framing) a okienkovanie

Akustický signál výstrelu je proces, ktorého štatistické vlastnosti sa v čase rýchlo menia (je nestacionárny). Klasická Fourierova transformácia však predpokladá, že frekvenčné zložky signálu sú v čase konštantné. Z tohto dôvodu sa využíva metóda **krátkodobej analýzy**, pri ktorej sa signál rozdelí na krátke úseky, nazývané **rámce** (frames), v rámci ktorých možno signál považovať za kvázistacionárny.[21]


Parametre rámčovania: V implementovanom algoritme boli zvolené parametre s vysokým časovým rozlíšením, čo je nevyhnutné pre správne zachytenie rýchleho náběhu rázovej vlny (shockwave):

- **Dĺžka rámca** ($T_f = 2.5 \text{ ms}$): Pri vzorkovacej frekvencii 22 050 Hz zodpovedá jeden rámec dĺžke približne 55 vzoriek. Táto krátka dĺžka zabezpečuje, že spektrálne charakteristiky výstrelu nie sú spriemerované s okolitým šumom.
- **Posun rámca** ($T_s = 1.0 \text{ ms}$): Určuje vzdialenosť medzi začiatkami susedných rámcov.
- **Prekrytie (Overlap)**: Susedné rámce sa prekrývajú o 1,5 ms (60 %), čo zabezpečuje kontinuitu informácie a kompenzuje stratu energie na okrajoch rámcov spôsobenú procesom okienkovania.

Okienkovanie (Windowing): Prechod medzi rámcami spôsobuje na ich okrajoch diskontinuity, ktoré vedú k nežiaducemu **spektrálnemu úniku** (spectral leakage). Tento jav sa potláča aplikáciou Hammingovho okna, ktoré plynule tlmí okraje každého rámca podľa vzťahu[21]:

$$w(n) = 0.54 - 0.46 \cos\left(\frac{2\pi n}{N-1}\right) \quad (4.1)$$

kde $0 \leq n \leq N-1$ a N je počet vzoriek v rámci.




Obrázok 4.2: Samostatný rámec signálu po aplikovaní Hammingovho okna

4.2.2 Výpočet výkonového spektra

Pre každý rámec sa vypočíta diskretná Fourierova transformácia (FFT) s dĺžkou $N_{FFT} = 512$. Získané komplexné spektrum sa prevedie na výkonové spektrum (Power Spectrum)[21]:

$$P = \frac{1}{N_{FFT}} |FFT(x)|^2 \quad (4.2)$$




Obrázok 4.3: Výkonové spektrum prvého framu signálu

4.2.3 Výpočet magnitúdového spektra

Z komplexných koeficientov získaných po FFT sa vypočíta ich absolútna hodnota, ktorá predstavuje magnitúdu (amplitúdu) jednotlivých frekvenčných zložiek:

$$|X(k)| = \sqrt{\text{Re}\{X(k)\}^2 + \text{Im}\{X(k)\}^2} \quad (4.3)$$



Obrázok 4.4: Magnitúdove spektrum prvého rámca signálu

4.3 Melova filtračná banka a logaritmovanie

V tomto kroku sa lineárne výkonové spektrum transformuje na reprezentáciu s redukovaným počtom príznačkov, pričom dochádza k nelineárnej kompresii frekvenčnej osi[21].

4.3.1 Transformácia na Melovu škálu

Prechod z lineárnej frekvencie f [Hz] na Melovu škálu M [mel] je definovaný logaritmickým vzťahom:

$$M(f) = 2595 \cdot \log_{10}\left(1 + \frac{f}{700}\right) \quad (4.4)$$


Tento vzťah slúži na redistribúciu frekvenčných zložiek. Kým v nižších frekvenciách (pod 1000 Hz) je mapovanie takmer lineárne, pri vyšších frekvenciách dochádza k výraznej kompresii. Pre spätný prechod z Melovej škály na frekvenciu v Hz sa používa inverzný vzťah[21]:

$$f = 700 \cdot \left(10^{\frac{M}{2595}} - 1\right) \quad (4.5)$$

4.3.2 Konštrukcia filtračnej banky

V realizovanom algoritme je definovaných $n_{filt} = 40$ trojuholníkových filtrov. Proces ich návrhu prebieha v nasledujúcich krokoch[3]:

1. Určenie hraničných frekvencií (0 Hz až $f_s/2$) a ich prevod na Melovu škálu.
2. Lineárne rozdelenie Melovho rozsahu na $n_{filt} + 2$ ekvidištantných bodov.
3. Prevod týchto bodov späť na Hz a následne na indexy FFT binov.
4. Konštrukcia trojuholníkových funkcií $H_m(k)$, kde každý filter začína v stredovej frekvencii predchádzajúceho filtra a končí v stredovej frekvencii nasledujúceho filtra.



Obrázok 4.5: Melova banka filtrov

4.3.3 Filtrácia a integrácia energie

Aplikácia filtračnej banky na výkonové spektrum $P(k)$ sa realizuje pomocou maticového násobenia (skalárneho súčinu). Výsledná energia E v m -tom Melovom pásme je daná vzťahom[21]:

$$E_m = \sum_{k=0}^{N_{FFT}/2} P(k) \cdot H_m(k) \quad (4.6)$$

Týmto procesom sa pôvodných 257 spektrálnych binov (pre $N_{FFT} = 512$) redukuje na vektor 40 hodnôt, ktoré reprezentujú energetickú distribúciu signálu.


4.3.4 Logaritmická transformácia (dB)

Získané energie sú podrobené logaritmovaniu. Tento krok je nevyhnutný z dvoch dôvodov:

1. **Dynamický rozsah:** Akustické signály výstrelův vykazujú obrovské rozdiely v energiách medzi rázovou vlnou a šumom pozadia. Logaritmus komprimuje tento rozsah, čím stabilizuje vstup pre neurónovú sieť.
2. **Aditívna separácia:** Logaritmovaním sa multiplikatívne zložky signálu (napr. vplyv prenosového kanála alebo mikrofónu) menia na aditívne, čo uľahčuje následnú analýzu pomocou DCT.

V algoritme je pred logaritmovaním implementované ošetrenie numerickej stability. Hodnoty blízke nule sú nahradené minimálnym kladným číslom (floating-point epsilon $\epsilon \approx 2.22 \cdot 10^{-16}$), aby sa predišlo operácii $\log(0)$ [21]:

$$E_{dB} = 20 \cdot \log_{10}(\max(\epsilon, E_m)) \quad (4.7)$$



Obrázok 4.6: Melová filtračná banka energií pre jednotlivý rámec

4.4 Diskrétna kosínová transformácia (DCT)


Záverečným krokom extrakcie MFCC je aplikácia Diskrétnej kosínovej transformácie (konkrétne typu DCT-II) na vektor logaritmovaných energií E_{dB} . Táto operácia prevádza dáta z frekvenčnej oblasti do keprálnej oblasti (quefreny domain) podľa vzťahu[21]:

$$C_n = \sum_{m=1}^M E_{dB,m} \cos\left[\frac{\pi n}{M}\left(m - \frac{1}{2}\right)\right] \quad (4.8)$$

kde C_n je n-tý výsledný koeficient a M je počet Melových filtrov ($M=40$).
Význam transformácie pre klasifikáciu:

- **Dekorelácia:** Melove filtre sa navzájom prekrývajú, čo spôsobuje vysokú koreláciu medzi susednými energetickými pásmami. DCT tieto závislosti odstraňuje a poskytuje ortogonálne príznaky, ktoré sú vhodnejšie pre tréovanie neurónových sietí.
- **Kompresia energie:** Informácia o celkovom tvare spektrálnej obálky je po transformácii sústredená v nízkych koeficientoch. Vyššie koeficienty reprezentujú rýchle spektrálne zmeny a šum, ktoré sú pre klasifikáciu typu zbrane menej podstatné.

Formát výstupných dát: V implementácii bolo zachovaných prvých **12 koeficientov** pre každý časový rámec. Po aplikácii diskkrétnej kosínusovej transformácie (DCT) v procese výpočtu MFCC sa energia signálu koncentruje do koeficientov nižšieho rádu. Týchto prvých 12 koeficientov nesie najdôležitejšiu informáciu o makroskopickom tvare spektrálnej obálky (hlavný charakter akustického rázu). Koeficienty vyšších rádov naopak reprezentujú rýchle spektrálne zmeny a jemné detaily, ktoré sú v poľných podmienkach silno náchylné na šum. Ich orezaním (ponechaním len prvých 12) sa tak nielen redukuje výpočtová a pamäťová náročnosť modelu, ale funguje to aj ako prirodzený filter proti vysokofrekvenčnému rušeniu. V implementácii bolo preto z pôvodného segmentu (60 ms) po procese rámcovania extrahované pole s rozmermi 58×12 . Táto matica predstavuje kompaktný akustický „odtlačok“ výstrelu, ktorý vstupuje do klasifikačného modelu ako dvojrozmerné pole[21].



Obrázok 4.7: Mel frekvenčné keprálne koeficienty jedného rámca

Kapitola 5

Konvolučná Neurónová sieť - CNN

5.1 Príprava a formátovanie vstupných dát

Výstupom predchádzajúcej fázy spracovania signálu a extrakcie príznakov je kompaktný „akustický odtlačok“ výstrelu vo forme matice Mel-frekvenčných kepstrálnych koeficientov (MFCC). Tieto extrahované dáta predstavujú priamy vstup pre klasifikačný model konvolučnej neurónovej siete (CNN).

Jednotlivé segmentované udalosti, zahŕňajúce reálne výstrely aj negatívne vzorky (non-gunshot), boli predspracované a uložené vo formáte binárnych súborov .npy. Tento formát umožňuje efektívne načítanie viacrozmerných polí do operačnej pamäte prostredníctvom knižnice NumPy. Každá načítaná matica disponuje fixnými rozmermi 58×12 , kde hodnota 58 reprezentuje počet časových rámcov (časová os) a hodnota 12 zodpovedá počtu zachovaných kepstrálnych koeficientov (zodpovedajúce frekvenčnej obálke signálu).



Obrázok 5.1: Formát uložených dát kepstrálnych koeficientov impulzných udalostí

Konvolučné neurónové siete sú architekturné optimalizované na spracovanie obrazových dát. Z tohto dôvodu vyžadujú na vstupe viacrozmerný tenzor v štandardizovanom tvare: (počet_vzoriek, výška, šírka, počet_kanálov). Keďže získaná matica MFCC koeficientov predstavuje dvojrozmernú časovo-frekvenčnú mapu, pristupuje sa k nej v kontexte CNN analogicky ako k čiernobielymu obrázku (tzv. grayscale)[22]. Pre splnenie vstupných požiadaviek siete bola preto vykonaná tvarová transformácia (reshape) pôvodných dát pridaním dodatočnej dimenzie, ktorá reprezentuje jeden dátový kanál. Výsledný tvar vstupného tenzoru pre jednu akustickú vzorku nadobudol formát (58,12,1).


Súbežne s formátovaním vstupných matíc bol vytvorený vektor cieľových tried (labels), ktorý je nevyhnutný pre proces učenia s učiteľom (supervised learning). Keďže cieľom práce je binárna klasifikácia, dátam bola priradená príslušná číselná hodnota:

- **Trieda 1 (Pozitívna):** Priradená impulzom delostreleckej palby.
- **Trieda 0 (Negatívna):** Priradená kategórii non-gunshot.

Takto sformátovaný a označený dataset tvorí základ pre následné tréningovanie a evaluáciu architektúry hlbokého učenia. K dispozícii bol dataset pozostávajúci zo 152 unikátnych vzoriek (62 výstrelův a 90 negatívnych vzoriek). Dáta boli rozdelené na tréningovú (80 %) a testovaciu (20 %) množinu.

5.2 Návrh architektúry a topológie CNN

Pre úlohu binárnej klasifikácie delostreleckej strelby bola navrhnutá sekvenčná architektúra konvolučnej neurónovej siete (CNN). Topológia siete je koncipovaná tak, aby dokázala efektívne extrahovať relevantné časovo-frekvenčné príznaky z matic MFCC a zároveň si udržala primeranú výpočtovú zložitosť vhodnú pre potenciálne nasadenie v prenosných detekčných zariadeniach.[23]



Obrázok 5.2: Topológia a architektúra konvolučnej neurónovej siete


Základom architektúry je proces postupnej extrakcie príznakov (feature extraction) a následnej klasifikácie. Sieť prijíma na vstupe tenzory s rozmerom (58,12,1) a pozostáva z nasledujúcich kľúčových blokov:

5.2.1 Prvý konvolučný blok

Vstupuje do neho formátovaná matica MFCC. Blok začína vrstvou 2D konvolúcie (Conv2D), ktorá obsahuje 32 paralelných filtrov s veľkosťou jadra (kernel size) 3×3 [23]. Úlohou týchto filtrov je detekovať nízkoúrovňové vizuálne vzory v spektrograme, akými sú napríklad strmé hrany reprezentujúce nábeh rázovej vlny. Ako aktivačná funkcia bola zvolená nelineárna funkcia ReLU (Rectified Linear Unit), ktorá zmierňuje problém miznúceho gradientu.

Na redukciu priestorovej dimenzionality a zabezpečenie čiastočnej invariančnosti voči malým časovým posunom signálu nadväzuje vrstva maximálneho zhukovania (MaxPooling2D) s veľkosťou okna 2×2 . [23]

Detail 1. Konvolučného bloku



Obrázok 5.3: Prvá konvolučná vrstva

Jeho hlavným cieľom je extrakcia nízkoúrovňových charakteristík (hrany a prudké zmeny amplitúdy v kepstrálnej oblasti), ktoré sú typické pre rázovú vlnu delostreleckého výstrelu.

Ako ilustruje Obrázok 4.3, blok sa skladá z dvoch funkčných vrstiev, pričom každá z nich modifikuje tvar prechádzajúceho tenzoru:


- **Konvolučná vrstva (Conv2D):** Pri konvolúcii bez doplnenia okrajov nuly (tzv. "valid padding") dochádza k zmenšeniu priestorových rozmerov mapy príznakov [24]. Pre os zodpovedajúcu časovému rámcu (58) sa rozmer zmenší na $58 - 3 + 1 = 56$. Podobne pre os kepstrálnych koeficientov (12) sa rozmer zmenší na $12 - 3 + 1 = 10$. Výsledkom tejto operácie a následnej nelineárnej aktivácie (ReLU) je nový tenzor s rozmermi (56,10,32).
- **Združovacia vrstva (MaxPooling2D):** Pre redukciu výpočtovej náročnosti, zmenšenie počtu parametrov a zabezpečenie odolnosti modelu voči miernemu časovému posunu výstrelu v rámci 60-milisekundového okna nasleduje vrstva zhukovania s maximom (Max Pooling). [25] S využitím okna s veľkosťou 2×2 a neprekrývajúcim sa krokom (stride) dôjde k polovičnému zredukovaniu rozmerov v oboch osiach. Výstupný tenzor z prvého bloku, ktorý následne putuje do hlbších častí siete, tak nadobúda konečné rozmery (28,5,32).

5.2.2 Druhý konvolučný blok

Druhý konvolučný blok nadväzuje na výstupy prvého bloku a jeho primárnou úlohou je detekovať zložitejšie a abstraktnejšie súvislosti v dátach. Zatiaľ čo

prvý blok sa sústredil na izolované hrany a jednoduché frekvenčné výkyvy, druhý blok na základe predchádzajúcich príznakov identifikuje ucelené štruktúry, akými sú napríklad typický časový rozostup a energetická korelácia medzi zložkou rázovej vlny (shockwave) a ústovej vlny (muzzle blast).

Detail 2. Konvolučného bloku



Obrázok 5.4: Druhá konvolučná vrstva

Ako znázorňuje Obrázok 4.4, proces spracovania prebieha v dvoch nasledujúcich krokoch:


- **Konvolučná vrstva (Conv2D):** Na vstupný tenzor z prvého bloku, ktorý má rozmery (28,5,32), je aplikovaných 64 konvolučných filtrov. Zvýšenie počtu filtrov zo 32 na 64 je štandardným architektonickým postupom (tzv. "lievikový efekt" naopak), ktorý umožňuje sieti vytvoriť hlbšiu priestorovú reprezentáciu napriek tomu, že fyzické rozmery mapy sa zmenšujú.[25] Filtre majú opäť jadro (kernel) o veľkosti 3×3 a na ich výstupy je aplikovaná aktivačná funkcia ReLU. Pri konvolúcii bez doplnenia okrajov sa rozmery tenzoru v oboch osiach opäť zredukujú. Časová os sa zmenší z 28 na $28 - 3 + 1 = 26$ a os príznakov z 5 na $5 - 3 + 1 = 3$. Výstupný tenzor tejto vrstvy má preto rozmer (26,3,64).
- **Združovacia vrstva (MaxPooling2D):** Podobne ako v prvom bloku, aj tu nasleduje proces redukcie dimenzionality. Združovanie s maximom (Max Pooling) s oknom o veľkosti 2×2 vykoná polovičné zmenšenie priestorových rozmerov[24]. Výsledkom je výstupný tenzor o veľkosti (13,1,64), ktorý predstavuje vysoko komprimovanú reprezentáciu pôvodného akustického signálu.

Tento výsledný tenzor následne opúšťa konvolučnú časť siete a putuje do klasifikačnej (plne prepojenej) časti, ktorej detail je popísaný v nasledujúcej sekcii.

5.2.3 Klasifikačná časť: Sploštenie a plne prepojené vrstvy

Po prechode konvolučnými blokmi sieť úspešne identifikovala kľúčové lokálne a abstraktné vzory ukryté vo frekvenčnom spektre. Aby však mohla sieť na základe týchto príznakov urobiť finálne rozhodnutie, musia byť priestorové (3D) tenzory transformované a odovzdané klasifikačnej sekcii – takzvaným plne prepojeným vrstvám (Fully Connected / Dense Layers).

Detail Klasifikačnej časti (Sploštenie a Plne prepojené vrstvy)



Obrázok 5.5: Klasifikačné vrstvy

Tento prechod a nasledujúce operácie sú detailne zachytené na Obrázku 4.5 a prebiehajú v týchto krokoch:

- **Sploštenie (Flatten):** Výstupom druhého konvolučného bloku je 3D tenzor o rozmeroch (13,1,64), ktorý reprezentuje 64 rôznych máp príznakov, každú o veľkosti 13×1 . Plne prepojené vrstvy, ktoré tvoria klasifikátor, však matematicky vyžadujú na svojom vstupe výhradne jednorozmerný vektor. Úlohou vrstvy Flatten je zoskupiť všetky hodnoty z týchto dimenzií do jednej roviny[26]. Výpočet dĺžky výsledného vektora je určený súčinom rozmerov predchádzajúceho tenzoru: $13 \cdot 1 \cdot 64 = 832$. Výstupom vrstvy Flatten je teda jednorozmerný vektor s 832 prvkami.
- **Plne prepojená skrytá vrstva (Dense):** Tento 832-prvkový vektor vstupuje do klasickej vrstvy viacvrstvového perceptrónu. Zvolená vrstva obsahuje 64 skrytých neurónov, pričom každý neurón je prepojený s každým vstupným prvkom. Architektúra opäť využíva aktivačnú funkciu ReLU.
- **Regularizácia (Dropout):** V rámci architektúry hlbokých neurónových sietí sú plne prepojené vrstvy obzvlášť náchylné na zapamätanie si tréningových dát, takzvané pretrénovanie (Overfitting). Preto je za skrytú Dense vrstvu integrovaná technika Dropout s parametrom 0,5 (resp. 50 %). Táto regularizačná metóda zabezpečuje, že počas každého tréningového kroku sa náhodne ignoruje (vypne) polovica neurónov, čím

sieť stráca možnosť spoliehať sa len na určité cesty a je nútená hľadať robustnejšie kauzality v akustickom podpise výstreľu.[27]

- **Výstupná klasifikačná vrstva (Output Dense):** Záverečným prvkom architektúry je plne prepojená vrstva, ktorá obsahuje iba 1 výstupný neurón. Na rozdiel od predchádzajúcich vrstiev využíva aktivačnú funkciu typu Sigmoid. Táto funkcia matematicky stláča akýkoľvek reálny vstup do obmedzeného intervalu $\langle 0,1 \rangle$ [28]. Výstupná hodnota tak slúži ako pravdepodobnostný indikátor: hodnoty blízke 1 predstavujú prítomnosť delostreleckého výstrelu (trieda Gunshot), zatiaľ čo hodnoty blízke 0 indikujú inú, negatívnu udalosť (trieda Non-gunshot).

Kapitola 6

Trénovanie, evaluácia a porovnanie


6.1 Trénovanie a evaluácia základného modelu

V tejto fáze práce som pristúpil k experimentálnemu overeniu navrhnutej architektúry CNN na pôvodných, neupravených dátach. Cieľom tohto kroku bolo získať takzvanú referenčnú úspešnosť (baseline), voči ktorej budeme môcť porovnávať ďalšie vylepšenia.

Pre experiment bol využitý kompletný dataset obsahujúci približne 70 unikátnych impulzných udalostí delostrelectva a doplnková kategória negatívnych vzoriek (non-gunshot), reprezentujúca iné rušivé zvuky ako tresknutie dvermi či ľudský výkrik. Celkový dataset v počte 152 vzoriek bol rozdelený na trénovaciu (80 %) a testovaciu (20 %) množinu. Pri rozdeľovaní bola striktne uplatnená metóda stratifikácie, aby bol v oboch množinách zachovaný identický pomer pozitívnych a negatívnych tried.

6.1.1 Počiatočné výsledky a indikácia pretrénovania

Model bol trénovaný po dobu 50 epoch s využitím optimalizátora Adam[29] a dávkovaním (batch size) o veľkosti 8 vzoriek. Už v raných fázach trénovania začala chybová funkcia (Loss) na testovacej sade rapídne klesať k nule a celková presnosť (Accuracy) dosiahla hranicu **100 %**.



Obrázok 6.1: Úspešnosť na trénovacej a validačnej vzorke

Hoci sa takýto výsledok môže javiť ako ideálny, v kontexte strojového učenia a analýzy signálov z reálneho prostredia ide o anomáliu. Takto vysoká presnosť na veľmi malom datasete (kde testovacia sada obsahovala len približne 30 vzoriek) jednoznačne indikuje dva fundamentálne problémy:

1. **Pretrénovanie (Overfitting):** Hlboká sieť disponuje dostatočnou kapacitou na to, aby sa pri malom objeme dát nadmerne prispôbila špecifickému šumu pozadia prítomnému v konkrétnych nahrávkach, namiesto toho, aby zovšeobecnila fyzikálne vlastnosti rázovej a ústovej vlny.
2. **Triviálna separabilita tried:** Negatívne akustické vzorky sú vo svojej kepstrálnej podstate natoľko odlišné od výstrelu, že na ich úspešné odlíšenie postačuje elementárna rozhodovacia hranica bez nutnosti extrakcie komplexných vzorov.

6.1.2 Závažový test (Stress Test) a analýza robustnosti

Keďže akustický detektor musí v reálnom nasadení spoľahlivo fungovať v podmienkach silného environmentálneho rušenia (vietor, dážď, hluk bojiska), pristúpili sme k testovaniu robustnosti referenčného modelu.

Navrhnutý záťažový test (Stress Test) spočíval v injekcii bieleho Gaussovho šumu (AWGN – Additive White Gaussian Noise) priamo do MFCC matíc[30] testovacej sady. Šum bol generovaný v rôznych intenzitách, aby simuloval klesajúci odstup užitočného signálu od šumu (SNR – Signal-to-Noise Ratio).

Výsledky záťažového testu odhalili zraniteľnosť referenčného modelu:

Veľkosť šumu - SNR [db]	Úspešnosť na validačných dátach
30 (Takmer čisté dáta)	96.72 %
20 (Stredný šum)	75.41 %
10 (Veľmi zašumené)	59.02 %
5 (Veľmi zašumené)	59.02 %

Tabuľka 6.1: Výsledok klasifikácie pre zašumené dáta (reálne podmienky).

Vzhľadom na fakt, že ide o binárnu klasifikáciu, presnosť blížiac sa k 50 % predstavuje úroveň náhodného tipovania. Tento experimentálny výsledok potvrdil hypotézu o pretrénovaní. Referenčný model v reálnych, zašumených podmienkach úplne zlyháva, čo preukázalo nevyhnutnosť implementácie techník pre umelé zväčšenie datasetu a zvýšenie robustnosti. Hoci sa pri menších datasetoch teoreticky zvažuje využitie krížovej validácie (K-fold cross-validation), pre ciele tejto práce bolo nevyhnutné zachovať fixnú testovaciu množinu (tzv. holdout set). Tento prístup zaručil metodicky čisté a konzistentné porovnávanie výkonnosti naprieč všetkými fázami vývoja, predovšetkým pri exaktnom meraní vplyvu kvantizácie na cieľovom hardvéri ESP32-S3.

6.2 Zvýšenie robustnosti: Augmentácia dát

Záťažový test referenčného modelu popísaný v predchádzajúcej sekcii odhalil zraniteľnosť architektúry pri detekcii reálnych, zašumených signálov. Na vyriešenie problému s pretrénovaním (Overfitting) a na zabezpečenie robustnosti modelu bola zvolená technika umelej augmentácie trénovacej množiny, konkrétne pridávanie šumu priamo do poľa príznakov (Feature Jittering).


Keďže vstupom do konvolučnej siete nie je surový audio signál, ale vypočítaná matica Mel-frekvenčných kepstrálnych koeficientov (MFCC), proces pridávania šumu prebiehal odlišne ako štandardné mixovanie audia. Do matíc príznakov bol iteratívne aplikovaný aditívny biely Gaussovský šum (AWGN). Tento proces možno matematicky vyjadriť ako:

$$MFCC_{noisy}(t, f) = MFCC_{clean}(t, f) + \mathcal{N}(0, \sigma^2) \quad (6.1)$$

kde $\mathcal{N}$ predstavuje normálne rozdelenie so strednou hodnotou 0 a rozptylom σ^2 [31]. Hodnota σ (smerodajná odchýlka šumu) bola škálovaná proporčne na základe celkovej smerodajnej odchýlky pôvodnej čistej matice MFCC, čím sa dosiahla kontrolovaná úroveň znehodnotenia príznakov.

Pôvodných 152 čistých vzoriek bolo najskôr rozdelených na trénovaciu a testovaciu množinu (80% trénovacie dáta a 20% testovacie). Následne trénovacia množina bola augmentovaná tak, že boli algoritmicky vygenerované štyri nové, zašumené verzie s rôznou úrovňou intenzity šumu (reprezentované koeficientmi zosilnenia 0.1, 0.2, 0.3 a 0.5 voči smerodajnej odchýlke signálu). Týmto krokom sa zväčšil počet dát – z pôvodných 152 na celkových **608**.

Proces augmentácie dát (Feature Jittering)



Obrázok 6.2: Bloková schéma procesu augmentácie dát v kepstrálnej oblasti.

Cieľom tohto procesu nebolo len umelo zväčšiť počet dát. Hlavným zámerom bolo prinútiť konvolučnú sieť počas tréningu ignorovať špecifický šum pozadia v jednotlivých nahrávkach a sústrediť sa výlučne na dominantné hrany a vzory, ktoré sú invariantné voči šumu.


6.3 Trénovanie a evaluácia augmentovaných dát

Po implementácii augmentačnej techniky v kepstrálnej oblasti (Feature Jittering) bol vytvorený rozšírený dataset pozostávajúci zo 760 vzoriek (kombinácia čistých a zašumených MFCC matíc rôznych úrovní SNR). Tento dataset bol následne rozdelený na trénovaciu (80 %, cca 608 vzoriek) a testovaciu množinu (20 %, cca 152 vzoriek).

6.3.1 Priebeh učenia a parametre siete

Finálny model so zhodnou topológiou (ako je popísaná v sekcii 4.2) bol trénovaný po dobu 50 epoch s využitím optimalizačného algoritmu Adam a stratovej funkcie binárnej krížovej entropie (Binary Crossentropy)[32]. Vzhľadom na zväčšený objem dát bola sieť schopná lepšie využiť regularizačnú vrstvu Dropout (0,5), ktorá zabráňovala okamžitému zapamätaniu si vzoriek.

Priebeh trénovania preukázal stabilnú konvergenciu. Zatiaľ čo pri referenčnom modeli klesala chybová funkcia k nule okamžite (čo indikovalo pretrénovanie), pri augmentovanom modeli bol pokles funkcie Loss na trénovacej aj validačnej množine plynulejší.



Obrázok 6.3: Úspešnosť na trénovacej a validačnej vzorke augmentovaných dát.

6.3.2 Stress test na augmentovaných dátach

Po ukončení trénovacieho procesu bol model verifikovaný na testovacej množine neznámych dát. Finálna konvolučná sieť dosiahla na testovacích dátach vynikajúcu celkovú presnosť blížiacu sa k 100 %.


Veľkosť šumu - SNR [db]	Úspešnosť na validačných dátach
30	96.71 %
20	96.05 %
10	94.74 %
5	94.08 %
0	90.13 %

Tabuľka 6.2: Výsledok klasifikácie augmentovaných dát pri šume.

Zásadný rozdiel oproti referenčnému modelu však spočíva v jeho správaní v zhoršených akustických podmienkach. Trénovanie na umelo zašumených dátach viedlo k vzniku robustného klasifikátora. Kým pôvodný model pri poklese SNR na úroveň 10 dB zlyhával a jeho úspešnosť padala na úroveň náhodného tipovania (cca 59 %), augmentovaný model si vďaka naučenej invariancii voči bielemu šumu dokáže aj v týchto podmienkach udržať vysokú mieru úspešnosti detekcie (nad 90 %).

6.3.3 Pretrénovanie na zašumených dátach

Pre overenie optimálnej dĺžky trénovacieho procesu bol vykonaný experiment s extrémnym predĺžením trénovania na 500 epoch.



Obrázok 6.4: Priebeh evaluácie pri 500 epochách na augmentovaných dátach.

Po prekročení hranice približne 50 epoch začala úspešnosť na trénovacej množine (modrá krivka) konvergovať k 100 %, pričom validačná úspešnosť (oranžová krivka) už nevykazovala žiadne zlepšenie. Tento roztvárajúci sa

rozdiel a narastajúca nestabilita validačnej krivky jednoznačne indikujú nástup pretrénovania (Overfitting v čase). Model si po dlhom čase začal pamätať aj aplikovaný umelý šum. Z tohto dôvodu bol počet tréningových epoch pre finálny model striktné obmedzený na 50 (tzv. Early Stopping[28]), čo predstavuje ideálny kompromis medzi naučením sa komplexných príznakov a zachovaním robustnosti.

6.4 Porovnanie a zhodnotenie výsledkov

V tejto sekcii sú porovnané výsledky, kedy bola neurónová sieť natrénovaná len na pôvodných dátach a keď bola natrénovaná na augmentovaných (zašumených) dátach, ktoré boli pridané k pôvodným.

Porovnanie je znázornené v nasledujúcej tabuľke:

Veľkosť šumu - SNR [dB]	Pôvodné dáta	Augmentované dáta
30	96.72 %	96.71 %
20	75.41 %	96.05 %
10	59.02 %	94.74 %
5	59.02 %	94.08 %

Tabuľka 6.3: Porovnanie úspešnosti klasifikácie pre pôvodné/augmentované dáta.

Z nameraných hodnôt v tabuľke 6.3 je zrejmé, že oba modely dosahujú pri vysokej kvalite signálu (SNR 30 dB) takmer identickú, mimoriadne vysokú úspešnosť presahujúcu 96,7 %. Tento výsledok potvrdzuje, že topológia navrhnutej konvolučnej neurónovej siete je pre túto klasifikačnú úlohu zvolená správne.

Zásadné rozdiely sa však začnú prejavovať pri zhoršených akustických podmienkach. Pri modeli tréňovanom výlučne na pôvodných (nezašumených) dátach dochádza k rapidnému poklesu úspešnosti. Už pri strednom zašumení (SNR 20 dB) klesá presnosť o viac ako 21 percentuálnych bodov. Pri silnom šume (SNR 10 dB a 5 dB) sa úspešnosť referenčného modelu prepadá až na úroveň 59,02 %. Tento jav experimentálne potvrdzuje predpoklad o pretrénovaní (overfitting) základného modelu, ktorý sa naučil rozpoznávať špecifický šum čistých nahrávok, no nepochopil zovšeobecniteľnú podstatu tvaru výstrelu.

Na druhej strane, model natrénovaný na augmentovanom datasete vykazuje odolnosť voči degradácii signálu. Ako vidno z výsledkov, pri SNR 20 dB si model udržiava takmer nezmenenú presnosť 96,05 %. Ešte významnejší je fakt, že aj v podmienkach extrémneho šumu (SNR 5 dB), kde je akustický impulz výstrelu výrazne maskovaný hlukom pozadia, si augmentovaný klasifikátor udržiava úspešnosť detekcie na úrovni 94,08 %. V týchto náročných podmienkach tak augmentácia priniesla zlepšenie o viac ako 35 percentuálnych bodov oproti referenčnému modelu.

6.5 Zväčšenie súboru dát typu „non-gunshot“

S cieľom zvýšiť objektivitu a robustnosť výsledkov bolo rozhodnuté o rozšírení množiny vzoriek impulzných udalostí typu „non-gunshot“. Opätovnou analýzou databázy poskytnutej vedúcim práce a doplnením o voľne dostupné zvukové záznamy z internetových zdrojov (rôzne typy ručných palných zbraní, ktoré nie sú predmetom primárnej detekcie) sa podarilo rozšíriť triedu „non-gunshot“ na **644** vzoriek. Množina cieľových výstrelů z hůfnice DANA zostala zachovaná v počte **62** vzoriek.

6.5.1 Problém s nevyváženým datasetom

Z celkového počtu **706** vzoriek tvorí minoritnú triedu len približne **8,8 %** dát. Pri takto výrazne nevyváženom datasete vzniká riziko, že model bude vykazovať vysokú celkovú presnosť (Accuracy) aj v prípade, ak bude nekriticky klasifikovať všetky vzorky ako väčšinovú triedu „non-gunshot“. Takýto výsledok by však bol z hľadiska detekcie cieľového javu nepoužiteľný. Na elimináciu tohto javu bolo implementované **váženie tried** (class weighting[33]), ktoré pri výpočte stratovej funkcie (Loss) priradzuje chybe v minoritnej triede vyššiu váhu, čím núti sieť venovať zvýšenú pozornosť správnej identifikácii výstrelů.

6.5.2 Matica zámien (Confusion Matrix)

Oveľa účinnejšia štatistika ako len úspešnosť binárnej klasifikácie je pri nevyváženom datasete takzvaná „Confusion Matrix“ (**Matica zámien**), ktorá ponúka poznatky ako **precision**, **recall** a **f1-score**[34].

	precision	recall	f1-score
Iný hluk (0)	1.00	0.92	0.96
DANA (1)	0.56	1.00	0.71
accuracy			0.93
macro avg	0.78	0.96	0.84
weighted avg	0.96	0.93	0.94

Obrázok 6.5: Príklad matice zámien pri evaluácii

Pre takto veľmi nevyvážené datasety je v strojovom učení preferovaná metrika Matthews Korrelačný koeficient (Matthews Correlation Coefficient) **MCC**. F1-score totiž ignoruje True Negatives (správne odhadnuté ticho/hluk). MCC naopak berie do úvahy všetky štyri kvadranty matice zámien (TP, TN, FP, FN).[35]

■ Matthewsov Korelačný koeficient (Matthews Correlation Coefficient) MCC

Matthewsov korelačný koeficient (MCC) predstavuje jednu z najrobustnejších metrik pre vyhodnocovanie kvality binárnych klasifikátorov, a to predovšetkým v prípadoch extrémne **nevyvážených datasetov**. Na rozdiel od tradičného F1-skóre, ktoré zohľadňuje iba správne klasifikované pozitívne vzorky (True Positives) a chyby s nimi spojené, MCC do výpočtu symetricky zahŕňa všetky štyri kvadranty matice zámien, teda aj správne klasifikované negatívne vzorky (True Negatives).[35]

Matematicky je MCC definovaný vzťahom:

$$MCC = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \quad (6.2)$$

kde premenné reprezentujú jednotlivé zložky matice zámien:

- **TP (True Positive)** – správne detekovaný výstrel z húfnice,
- **TN (True Negative)** – správne detekovaný hluk prostredia,
- **FP (False Positive)** – falošný poplach (hluk označený za výstrel),
- **FN (False Negative)** – prehliadnutý výstrel.

Hodnota koeficientu nadobúda spojitý interval od -1 do $+1$:

- **+1** predstavuje dokonalú predikciu,
- **0** zodpovedá náhodnému tipovaniu (model nemá žiadnu predikčnú schopnosť),
- **-1** indikuje úplný nesúlad (model predikuje presný opak skutočnosti).

V kontexte tejto práce, kde **majoritnú triedu tvorí hluk prostredia** (vysoké hodnoty TN), poskytuje MCC oveľa objektívnejší pohľad na celkovú výkonnosť neurónovej siete. Na rozdiel od metriky celkovej presnosti (Accuracy), ktorá by pri naivnej klasifikácii všetkých vstupov ako "hluk" dosahovala zdanlivo vynikajúce hodnoty, MCC by takýto nefunkčný model nekompromisne penalizovalo hodnotou blížiacou sa k nule.

Nasledujúca tabuľka vysvetľuje význam jednotlivých premenných v matici zámien.

Názov metriky	Význam
Precision	Presnosť pozitívnej predikcie. Vyjadruje pomer správne identifikovaných výstrelů (True Positives) ku všetkým udalosťam, ktoré model označil ako výstrel (True Positives + False Positives). Udáva spoľahlivosť alarmu.
Recall	Senzitivita modelu. Vyjadruje pomer správne identifikovaných výstrelů (True Positives) ku všetkým skutočným výstrelom v dátach (True Positives + False Negatives). Udáva úspešnosť záchytu.
F1-score	Harmonický priemer medzi metrikami Precision a Recall. Poskytuje komplexné zhodnotenie modelu, najmä v prípade nevyvážených tried, kde by samotná celková presnosť (Accuracy) bola zavádzajúca.
MCC	Komplexná metrika, ktorá zohľadňuje všetky štyri kvadranty matice zámien a je mimoriadne robustná voči extrémnej asymetrii tried. Nadobúda hodnoty od -1 do +1.

Tabuľka 6.4: Význam základných klasifikačných metrík odvodených z matice zámien.

6.6 Evaluácia robustnosti na augmentovanom datasete pri použití váh

Pred fázou tréovania bola množina vzoriek, podobne ako predtým, ešte augmentovaná kvôli zvýšeniu robustnosti (pomer tried ostal rovnaký). Po aplikovaní týchto dvoch kľúčových techník

- augmentácie dát pomocou keprálneho šumu (Feature Jittering)
- váženie tried (Class Weighting)

bol spustený proces tréovania neurónovej siete a následného monitorovania štatistík **matice** zámien, konkrétne metrík **recall** a **precision**. Tréovanie bolo znovu spustené na 50 epochách, na rovnakom modeli neuro-
novej siete.

6.6.1 Priebeh testovania pre jednotlivé váhové pomery

Úroveň šumu (SNR)	Accuracy	Precision	Recall	F1-score	MCC
30 dB	1.00	1.00	1.00	1.00	1.0000
20 dB	0.99	0.92	1.00	0.96	0.9571
10 dB	0.94	0.67	0.67	0.67	0.6359
5 dB	0.90	0.38	0.25	0.30	0.2552

Tabuľka 6.5: Výsledky evaluácie pre váhový pomer 1:1.

Úroveň šumu (SNR)	Accuracy	Precision	Recall	F1-score	MCC
30 dB	0.99	1.00	0.92	0.96	0.9538
20 dB	1.00	1.00	1.00	1.00	1.0000
10 dB	0.97	0.75	1.00	0.86	0.8526
5 dB	0.96	0.71	1.00	0.83	0.8239

Tabuľka 6.6: Výsledky evaluácie pre váhový pomer 1:2.

Úroveň šumu (SNR)	Accuracy	Precision	Recall	F1-score	MCC
30 dB	0.99	0.92	1.00	0.96	0.9571
20 dB	0.99	0.92	1.00	0.96	0.9571
10 dB	0.96	0.71	1.00	0.83	0.8239
5 dB	0.95	0.63	1.00	0.77	0.7730

Tabuľka 6.7: Výsledky evaluácie pre váhový pomer 1:3.

Úroveň šumu (SNR)	Accuracy	Precision	Recall	F1-score	MCC
30 dB	0.82	0.32	1.00	0.49	0.5118
20 dB	0.82	0.32	1.00	0.48	0.5026
10 dB	0.79	0.29	1.00	0.44	0.4688
5 dB	0.80	0.30	1.00	0.46	0.4852

Tabuľka 6.8: Výsledky evaluácie pre váhový pomer 1:4.

6.6.2 Zhodnotenie experimentu a analýza vplyvu váh

1. Zlyhanie referenčného modelu (Váha 1:1)

Referenčný model bez úpravy váh (Tabuľka 5.5) potvrdzuje absolútnu nevyhnutnosť riešenia asymetrie dát. Pri čistých dátach síce funguje excelentne, no so stúpajúcim šumom začína zlyhávať. Akonáhle SNR klesne na 5 dB, jeho úspešnosť záchytu kriticky padá (**Recall 0,25**). V praxi to znamená, že v hlučnom prostredí sieť ignoruje až 75 % reálnych výstrelů. Tento prepad výkonnosti objektívne odzrkadľuje aj rapídny pokles metriky **MCC na hodnotu 0,2552**. Pre bezpečnostné nasadenie je takýto model nepoužiteľný.

2. Nájdenie optimálneho pracovného bodu (Váha 1:2)


Už mierna korekcia váhového pomeru na 1:2 (Tabuľka 5.6) priniesla radikálne zlepšenie a predstavuje tzv. **optimálny pracovný bod** (*sweet spot*). Modelu stačila minimálna penalizácia na dosiahnutie bezchybného záchytu (**Recall 1,00**) naprieč celým spektrom šumu, a to bez extrémneho generovania falošných poplachů. Excelentnú stabilitu si model udržal aj pri extrémnom zarušení (5 dB), kde popri stopercentnom záchyte dosiahol vysoko akceptovateľnú **Precision 0,71** a komplexné **MCC skóre 0,8239**.

3. Degradácia a hypersenzitivita (Váhy 1:3 a 1:4)

Ďalšie zvyšovanie váh demonštruje klasický problém známy ako **Precision-Recall trade-off**. Pri váhe 1:3 (Tabuľka 5.7) už začína mierne klesať presnosť (Precision 0,63 pri 5 dB). Extrémnym prípadom je váha 1:4 (Tabuľka 5.8), kde sa model stal vyslovene **hypersenzitívnym**. Prehnany strach z penalizácie spôsobil, že sieť síce zachytila všetky výstrely (**Recall 1,00**), avšak za cenu drastického nárastu falošných poplachů. Hodnota **Precision klesla pri 5 dB na úroveň 0,30** a MCC sa prepadlo na 0,4852, čo by v reálnom nasadení znamenalo neustále spúšťanie falošných alarmů.[36]

4. Grafické zobrazenie výsledkov

Porovnanie vplyvu váh tried na metriku MCC pri rôznom SNR



Obrázok 6.6: Závislosť Matthewsovo korelačného koeficientu od úrovne šumu pre rôzne nastavenia váh tried.

Záver


Vzhľadom na špecifické logistické a bezpečnostné obmedzenia pri zbere akustických prejavov vojenskej techniky je získanie rozsiahleho datasetu v bežných podmienkach nerealizovateľné. Práca preto operuje s limitovaným, no o to vzácnejším súborom 62 reálnych výstrelů z hůfnice DANA. Tento nedostatok dát bol úspešne kompenzovaný technikami augmentácie a vhodnou penalizáciou tried. Samotný experiment preukázal, že navrhnutá CNN architektúra si nevyžaduje extrémne váženie. Ako finálny a najrobustnejší model bol vyhodnotený pomer **1:2**, ktorý ponúka najlepšiu harmóniu medzi maximálnou ostrážitosťou (nulové prehliadnutie hrozby) a odolnosťou voči šumu (minimum falošných poplachů).

Kapitola 7

Implementácia modelu na mikrokontrolér ESP32-S3

7.1 Popis použitého embedded zariadenia

Pre tento účel bol zvolený mikrokontrolér **ESP32-S3** disponujúci jadrom **Xtensa LX7**, ktorého hlavnou výhodou je hardvérová podpora **vektorových inštrukcií** (SIMD – Single Instruction, Multiple Data). Architektúra SIMD umožňuje spracovávať viacero dátových bodov súčasne, čo v spojení s optimalizačnou knižnicou **esp-nn** masívne urýchľuje výpočty konvolučných vrstiev a maticových násobení v navrhnutej sieti.[37, 39]



Obrázok 7.1: Embedded zariadenie ESP32-S3-DEVKIT.

Okrem výpočtového výkonu disponuje **ESP32-S3** kapacitou 512 KB vnútornej **SRAM** pamäte. Táto kapacita je nevyhnutná pre beh rámca TensorFlow Lite for Microcontrollers, ktorý vyžaduje dedikovaný blok operačnej pamäte na dynamické ukladanie tenzorov a medzivýsledkov výpočtov.[38]

Riadenie procesov zabezpečuje operačný systém reálneho času **FreeRTOS**[38]. Pre účely verifikácie modelu priamo na hardvéri sa využíva sériová zbernica **UART**, prostredníctvom ktorej mikrokontrolér obojsmerne komunikuje s nadradeným počítačom.

Pri implementácii bol kladený dôraz na efektivitu s cieľom zachovať kompatibilitu aj s hardvérovo obmedzenejšími embedded systémami, ako napríklad mikrokontroléry STM32. Tie v porovnaní s použitým modulom ESP32 typicky disponujú menšou kapacitou operačnej pamäte (SRAM) a úložiska (Flash). Kvantizácia modelu na 8-bitové celé čísla smeruje k univerzálnosti riešenia.

7.2 Konverzia a kvantizácia modelu

Štandardným výstupom tréovania v prostredí Keras/TensorFlow je model uložený vo formáte HDF5 (.h5). Tento formát však vyžaduje plnohodnotný súborový systém a operačnú pamäť na úrovni osobných počítačov, čo ho robí pre mikrokontroléry nepoužiteľným. Z tohto dôvodu bolo nevyhnutné model pred nasadením **transformovať**.

Pre tento účel bol využitý nástroj **TensorFlow Lite Converter**. Model bol najprv skonvertovaný do optimalizovaného formátu **.tflite**, pričom bola aplikovaná celočíselná kvantizácia po tréovaní (Post-Training Integer Quantization). Tento proces transformoval váhy a aktivácie modelu z 32-bitovej plávajúcej čiarky (**float32**) na **8-bitové celé čísla** (**int8**) [40]. Tým sa dosiahla štvornásobná redukcia pamäteovej stopy modelu, čo je kľúčové pre zariadenia s obmedzenou pamäťou **Flash**.

Riešením bolo transformovať binárny **.tflite** súbor do podoby hlavičkového súboru v jazyku C/C++ (tzv. *C-array*). Pomocou na mieru vytvoreného skriptu v jazyku Python bol model prevedený do obrovského pola hexadecimálnych hodnôt (súbor **model_data.h**). Takýto prístup umožňuje kompilátoru vložiť celú neurónovú sieť priamo do **Flash** pamäte mikrokontroléra určenú len na čítanie (*Read-Only Memory*), čím sa šetrí dynamická pamäť (RAM).

7.3 Vývojové prostredie a AI akcelerácia

Samotný detekčný softvér bol implementovaný v jazyku C++ v produkčnom prostredí **ESP-IDF**. [41]

Integrácia v prostredí ESP-IDF bola kľúčová najmä pre prepojenie frameworku TensorFlow Lite Micro s nízkoúrovňovou knižnicou **esp-nn** [41]. Kým štandardný TFLite Micro vykonáva matematické operácie sekvenčne, v navrhutej implementácii sú výpočty konvolúcií (**AddConv2D**) a plne prepojených vrstiev (**AddFullyConnected**) automaticky presmerované na optimalizované jadrá knižnice **esp-nn**. Týmto sa softvérovo aktivuje využitie hardvérových vektorových inštrukcií čipu ESP32-S3 (SIMD), ktoré sú špeciálne optimalizované pre prácu s 8-bitovými dátami (**int8**). Toto prepojenie skraca dobu inferencie z desiatok milisekúnd na jednotky, pri zachovaní dostatočnej presnosti klasifikácie.

Výzvou pri implementácii neurónových sietí na okrajových zariadeniach (Edge AI) je manažment operačnej pamäte. V programe bolo nutné vyhradiť statický blok pamäte, označovaný ako **tensor_arena**, ktorý slúži na ukladanie dočasných tenzorov a medzivýsledkov výpočtov (napr. výstupy po konvolučných filtroch). Veľkosť tejto pamäte bola empiricky stanovená na **80 KB**, čo bezpečne pokrýva požiadavky architektúry siete bez rizika pretečenia pamäte.

V navrhnutej implementácii bola využitá trieda `MicroMutableOpResolver`, ktorá umožňuje explicitne definovať a načítať len tie matematické operácie, ktoré model reálne využíva[42]:

- `AddConv2D()` – pre 2D konvolúciu nad maticou MFCC,
- `AddMaxPool2D()` – pre podvzorkovanie priestorových rozmerov,
- `AddFullyConnected()` – pre plne prepojené vrstvy klasifikátora,
- `AddRelu()` a `AddSoftmax()` – pre aktivačné funkcie,
- `AddReshape()` – pre zmenu tvaru tenzorov.

Vďaka tomuto prístupu sa dramaticky znížila celková spotreba dynamickej pamäte. Výsledná skompilovaná binárna aplikácia (zahŕňajúca operačný systém FreeRTOS, hardvérové ovládače ESP32-S3, framework TFLite Micro aj samotné váhy modelu) dosiahla veľkosť len približne 290 KB. Vzhľadom na to, že použitý vývojový modul ESP32-S3 disponuje integrovanou Flash pamäťou s kapacitou 8 MB (resp. 16 MB podľa konkrétnej verzie), zaberá celá implementácia menej ako 4 % celkovej fyzickej kapacity pamäte. To ponecháva obrovský priestor pre budúce rozširovanie funkcionality.

7.4 Verifikácia modelu a komunikácia cez rozhranie UART

Záverečnou fázou implementácie je overenie funkčnosti natrénovaného modelu priamo na cieľovom hardvéri. Keďže v tejto fáze vývoja nebol cieľom zber dát z fyzického mikrofónu, ale verifikácia matematického jadra a úspešnosti klasifikácie, bolo potrebné navrhnuť mechanizmus prenosu testovacích dát z počítača do mikrokontroléra.

7.4.1 Motivácia a protokol komunikácie

Pre potreby verifikácie bola zvolená sériová zbernica **UART** (Universal Asynchronous Receiver-Transmitter). Hlavným dôvodom je jej natívna podpora na väčšine embedded platforiem a jednoduchosť integrácie s vývojovým prostredím. Komunikácia prebieha obojsmerne:

- **Smer PC → ESP32-S3:** Prenos surových príznakov (MFCC koeficientov) vo forme binárneho prúdu dát.
- **Smer ESP32-S3 → PC:** Odosielanie výsledkov inferencie (pravdepodobnosť triedy) a diagnostických údajov (napr. čas výpočtu).

Pre zabezpečenie stability prenosu a dostatočnej priepustnosti bola prenosová rýchlosť nastavená na **115 200 baudov**.

Jed

$$(7.1)$$

Po

Až

Pr

Úroveň šumu (SNR)	Accuracy	Precision	Recall	F1-score	MCC
30 dB	99.86 %	1.00	0.98	0.99	0.9912
20 dB	99.29 %	1.00	0.92	0.96	0.9553
10 dB	96.18 %	1.00	0.56	0.72	0.7361
5 dB	94.62 %	0.93	0.42	0.58	0.6036

Tak

Ex

7.5.1 Zhodnotenie testovania a porovnanie s PC

Po úspešnom nasadení modelu na mikrokontrolér ESP32-S3 a získaní výsledkov z evaluácie (Tabuľka 7.1) bolo vykonané priame porovnanie s výsledkami dosiahnutými pri testovaní identického modelu (s optimalizovaným váhovým pomerom tried 1:2) v prostredí osobného počítača (Tabuľka 6.6).

Keďže oba testy využívali rovnaké vstupné matice MFCC a rovnaké váhy neurónovej siete, porovnanie odhaľuje vplyv samotnej hardvérovej a softvérovej architektúry na proces inferencie.

Správanie v priaznivých akustických podmienkach (30 dB a 20 dB)


Pri nízkej úrovni šumu (SNR 30 dB a 20 dB) dosahujú obe platformy excellentné výsledky, ktoré sú takmer identické. Celková presnosť (Accuracy) sa pohybuje nad úrovňou 99 % a metrika MCC je cez 0,95. V týchto podmienkach je akustický podpis výstrelu natoľko výrazný, že drobné odchýlky vo výpočtoch nemajú vplyv na finálne klasifikačné rozhodnutie siete.

Divergencia v zašumenom prostredí (10 dB a 5 dB)

Kľúčové rozdiely medzi platformami sa prejavujú pri výraznej degradácii užitočného signálu šumom (SNR 10 dB a 5 dB). V tomto bode môžeme pozorovať posun v charaktere klasifikátora:

- **Model na PC (Senzitívny charakter):** V prostredí PC si model udržiava dokonalú schopnosť záchytu ($\text{Recall} = 1,00$ aj pri 5 dB). Daňou za túto senzitivitu je však nárast falošných poplachov ($\text{Precision} 0,71$).
- **Model na ESP32-S3 (Konzervatívny charakter):** Na embedded zariadení vykazuje sieť opačný trend. Dokáže si udržať extrémne vysokú odolnosť voči falošným poplachom ($\text{Precision} = 1,00$ pri 10 dB a 0,93 pri 5 dB), avšak za cenu toho, že v silnom šume prehliadne značnú časť skutočných výstrelův (Recall klesá na 0,56 a následne až na 0,42).

Porovnanie výsledkov z PC a ESP32 na metriku MCC pri rôznom SNR



Obrázok 7.2: Porovnanie Matthewsovho korelačného koeficientu PC vs ESP32.

■ Analýza možných príčin odchýlok

Tento jav (kedy identický model s rovnakými vstupmi produkuje posunuté výsledky) je v oblasti implementácie neurónových sietí na okrajové zariadenia (Edge AI) bežný. Vzhľadom na to, že model bol pre nasadenie na mikrokontrolér kvantizovaný, túto divergenciu možno pripísať nasledujúcim faktorom:

1. **Kvantizačný šum a strata rozlíšenia:** Najzásadnejším rozdielom je prechod z 32-bitovej plávajúcej rádovej čiarky (PC) na 8-bitové celé čísla (ESP32-S3). Pri mapovaní vstupných MFCC koeficientov a vnútorných váh modelu do diskrétného rozsahu $\langle -128, 127 \rangle$ dochádza k nevyhnutnému zaokrúhľovaniu.
2. **Výpočtový rámec a hardvérová akcelerácia:** Kým PC využíva štandardný framework TensorFlow počítajúci v presnosti `float32`, ESP32-S3 využíva `TensorFlow Lite Micro`[42] prepojený s knižnicou `esp-nn`. Táto knižnica je striktne optimalizovaná pre celočíselné operácie a využíva vektorové inštrukcie (SIMD) jadra Xtensa. Matematická implementácia násobenia a akumulácie (MAC operácie) nad celými číslami sa fundamentálne líši od operácií s plávajúcou rádovou čiarkou.
3. **Rekvantizácia skrytých vrstiev a posun na výstupe:** Zatiaľ čo pri `float32` sa zachovávajú aj tie najmenšie desatinné medzivýsledky po každej vrstve, pri `int8` modeli sa výstup z každej konvolučnej vrstvy musí opätovne rekvantizovať a orezať do 8-bitového rozsahu, aby mohol vstúpiť do nasledujúcej vrstvy.[40] Tieto kaskádovité straty spôsobujú posun finálnej hodnoty pred aktivačnou funkciou *Sigmoid*. V hraničných prípadoch (silne zašumený výstrel), kde PC zachová dostatok detailov na výpočet pravdepodobnosti 0,52 (Klasifikácia: Výstrel), model na ESP32-S3 stratí časť informácie a vypočíta hodnotu 0,48 (Klasifikácia: Hluk/Ignorovať).

Kapitola 8

Validácia systému na zašumených audio vzorkách

Z hľadiska fyzikálnej vernosti a verifikácie v reálnych podmienkach je reprezentatívnejšie testovať model na audionahrávkach, do ktorých bol **šum pridaný ešte pred procesom extrakcie príznakov**[43]. Na rozdiel od priamej injekcie šumu do vypočítaných matíc MFCC (tzv. feature-level noise injection), tento prístup simuluje reálny akustický reťazec, v ktorom šum prechádza celým matematickým aparátom spracovania signálu — od okienkovania až po logaritmovanie v Melovej filtračnej banke. Táto kapitola sa preto venuje evaluácii na dátach, ktoré boli zašumené v časovej oblasti (Waveform level), pričom finálny akustický odtlačok bol extrahovaný až z takto modifikovaného signálu.

8.1 Matematický model zašumenia a výpočet SNR

Základným parametrom pre definovanie úrovne zašumenia je odstup užitočného signálu od šumu (SNR – Signal-to-Noise Ratio), vyjadrený v decibeloch (dB). Keďže audionahrávky z prostredia strelnice majú premenlivú amplitúdu, intenzita pridávaného šumu nemôže byť konštantná, ale musí byť dynamicky škálovaná na základe výkonu (resp. smerodajnej odchýlky) konkrétneho užitočného signálu.

Zašumený diskretný signál $x_{noisy}[n]$ sa vypočíta podľa nasledujúceho vzťahu:

$$x_{noisy}[n] = x[n] + k \cdot \mathcal{N}(0, \sigma_x^2) \quad (8.1)$$

kde:

- $x[n]$ je pôvodný (čistý) diskretný audiosignál,
- $\mathcal{N}(0, \sigma_x^2)$ je generovaný biely Gaussovský šum s nulovou strednou hodnotou a smerodajnou odchýlkou rovnajúcou sa smerodajnej odchýlke pôvodného signálu (σ_x),
- k predstavuje bezrozmerný multiplikátor (škálovací faktor) amplitúdy šumu.

Pre dosiahnutie exaktnej úrovne SNR definovanej v decibeloch je potrebné škálovací faktor k analyticky odvodiť. Vychádzajúc zo štandardnej definície SNR pre amplitúdy platí:

$$SNR_{dB} = 20 \cdot \log_{10} \left(\frac{1}{k} \right) \implies k = 10^{\frac{-SNR_{dB}}{20}} \quad (8.2)$$

Presné dodržanie týchto špecifických úrovní SNR pri generovaní šumu v časovej oblasti je kľúčové pre zabezpečenie konzistencie. Tento analytický prepočet umožňuje vytvoriť podmienky na priame a objektívne porovnanie výkonnosti modelu s predchádzajúcim experimentom (popísaným v kapitole 5 a 6), pri ktorom bol ekvivalentný šum injektovaný až v neskoršej fáze priamo do matíc kepstrálnych koeficientov (*Feature Jittering*). Takto bude relatívne presne možné overiť kvalitu implementácie pre fyzikálne presnejší šum.

8.2 Realizácia experimentu

Pre účely testovania klasifikátora na PC aj na zariadení ESP32-S3 boli na základe odvodenej rovnice algoritmicke vygenerované štyri zašumené varianty pre každú zo 706 pôvodných audionahrávok. Testované boli nasledujúce úrovne degradácie signálu:

- **SNR 30 dB** ($k \approx 0,0316$): Predstavuje takmer čistý signál, kde je šum akusticky len veľmi slabo badateľný.
- **SNR 20 dB** ($k = 0,1000$): Predstavuje mierny hluk prostredia, amplitúda šumu dosahuje 10 % smerodajnej odchýlky signálu.
- **SNR 10 dB** ($k \approx 0,3162$): Simuluje výrazný hluk bojiska alebo silný vietor pri mikrofóne.
- **SNR 5 dB** ($k \approx 0,5623$): Predstavuje extrémne nepriaznivé podmienky (limitný stav), kde energia šumu začína maskovať užitočné spektrálne zložky ústovej vlny výstrelu.

Každý takto synteticky znehodnotený zvukový súbor bol následne prehnaný kompletným extrakčným reťazcom, čím sa zabezpečilo, že vplyv šumu prirodzene prenikol cez nelineárne operácie (najmä logaritmickú transformáciu) až do finálnej 58×12 matice kepstrálnych koeficientov.

■ Výsledky testovania

Po úspešnej extrakcii matíc kepstrálnych koeficientov zo zašumených audiosignálov bolo realizované testovanie klasifikačnej úspešnosti. Pre účely evaluácie bol zámerne použitý už existujúci model, ktorý bol natrénovaný na dátach s využitím techniky injekcie šumu priamo do príznakov (*Feature Jittering*), detailne popísanej v kapitole 5.

Tento metodologický postup umožňuje overiť schopnosť modelu generalizovať získané vedomosti. Testuje sa tým hypotéza, či si model dokáže udržať svoju robustnosť a presnosť aj v situácii, keď aplikovaný šum prechádza celým nelineárnym procesom predspracovania signálu, čo presnejšie reflektuje fyzikálnu realitu nasadenia.

Testovanie prebehlo paralelne na dvoch platformách – v referenčnom prostredí osobného počítača (PC) a priamo na cieľovom hardvéri mikrokontroléra ESP32-S3. Namerané výsledky pre jednotlivé úrovne degradácie signálu (SNR) sú zaznamenané v tabuľkách 8.1 a 8.2.

Úroveň šumu (SNR)	Accuracy	Precision	Recall	F1-score	MCC
30 dB	84.41 %	0.35	1.00	0.52	0.5377
20 dB	82.86 %	0.33	1.00	0.49	0.5367
10 dB	81.12 %	0.31	0.99	0.47	0.4893
5 dB	80.44 %	0.29	0.93	0.45	0.4581

Tabuľka 8.1: Výsledky evaluácie na PC pre dáta zašumené v časovej oblasti (.wav).

Úroveň šumu (SNR)	Accuracy	Precision	Recall	F1-score	MCC
30 dB	99,86 %	1,00	0,98	0,99	0,9912
20 dB	99.73 %	0.98	0.98	0.98	0.9824
10 dB	97.78 %	0.86	0.87	0.87	0.8554
5 dB	97.18 %	0.95	0.70	0.81	0.8009

Tabuľka 8.2: Výsledky evaluácie na ESP32-S3 pre dáta zašumené v časovej oblasti (.wav).

V S

1

2


Vplyv extrémneho šumu na výsledky testovania

Pri takto veľkom zašumení (SNR 5dB) amplitúda šumu už výrazne deformuje maticu príznakov. Na rozdiel od PC, ktoré si aj pri veľkom zašumení zachováva vysoký percentil detekovaných výstrelov (**Recall 0.93**), ESP32-S3 reaguje tak, že za cenu zvýšenia počtu prehliadnutých výstrelov (**Recall 0.7**) je počet falošných poplachov relatívne malý (len cca 5% - podľa tabuľky 8.2 Precision 0.95). Vďaka tomu si stále drží vysoký koeficient MCC (okolo 0.8), no za cenu prehliadnutia približne 30% výstrelov.

Záver experimentu

Z aplikačného hľadiska tento experiment ukazuje zaujímavý fakt: **Kvantizácia** modelu pre platformu Edge AI nielenže redukuje pamäťové nároky a urýchľuje inferenciu na jednotky milisekúnd, ale paradoxne **zvyšuje fyzikálnu robustnosť detektora**. Tým, že zariadenie prirodzene stráca "citlivosť na detaily", stáva sa **odolnejším** voči bežnému environmentálnemu šumu a poskytuje spoľahlivé výsledky pre systémy včasného varovania (s minimalizáciou falošných poplachov).

Porovnanie MCC pre PC a ESP32 pri rôznom šume pridanom k audionahrávkam



Obrázok 8.1: Porovnanie Matthewsovho korelačného koeficientu PC vs ESP32.

8.4 Verifikácia vplyvu kvantizácie (int8) na PC


S cieľom definitívne potvrdiť hypotézu, že prechod z plnej presnosti (`float32`) na kvantizovaný formát (`int8`) pôsobí ako prirodzená šumová brána, bol realizovaný dodatočný verifikačný experiment. Evaluácia prebehla v referenčnom prostredí osobného počítača. Testovacie dáta boli najprv kvantizované na 8-bitové celočíselné hodnoty a následne klasifikované identickým TFLite modelom, aký bol nasadený na mikrokontroléri. Dosiahnuté výsledky sú zhrnuté v tabuľke 8.3.

Úroveň šumu (SNR)	Accuracy	Precision	Recall	F1-score	MCC
30 dB	98.66 %	0.86	1.00	0.93	0.9211
20 dB	96.77 %	0.72	1.00	0.84	0.8340
10 dB	92.74 %	0.54	0.97	0.69	0.6890
5 dB	92.41 %	0.53	0.90	0.66	0.6511

Tabuľka 8.3: Výsledky evaluácie na PC pre dáta zašumené v časovej oblasti (.wav) a kvantizované na int8.

Zhodnotenie vplyvu kvantizácie

Ako sa predpokladalo na základe testov v sekcii 8.3, zníženie rozlíšenia vstupných parametrov skutočne funguje ako efektívny filter. Výsledky evaluácie sú signifikantne lepšie a stabilnejšie v porovnaní s modelom využívajúcim plný rozsah desatinných čísel (`float32`). Vizuálne porovnanie celkovej robustnosti, reprezentovanej metrikou MCC, pre štandardný a kvantizovaný model bežiaci na PC, je znázornené na obrázku 8.2.



Obrázok 8.2: Porovnanie Matthewsovho korelačného koeficientu na PC pre nekvantizovaný a kvantizovaný model.

Kapitola 9

Diskusia

Navrhnuté a otestované riešenie problematiky detekcie akustických prejavov delostreleckej palby (konkrétne húfnice vz. 77 DANA) prinieslo významné poznatky, a to predovšetkým v kontexte nasadenia konvolučného modelu na platformu Edge AI, kde dochádzalo ku kompresii a kvantizácii dát.

Úvodná fáza práce sa zameriavala na predspracovanie surového akustického signálu do formátu vhodného pre klasifikačný algoritmus. Aplikovaná augmentácia dát preukázateľne zvýšila robustnosť modelu a čiastočne kompenzovala limitovaný rozsah datasetu pre pozitívnu triedu („gunshot“). Optimalizovaná knižnica `TensorFlow Lite Micro`, určená pre vnorené systémy, poskytla mimoriadne vysoký výpočtový výkon. Vďaka využitiu vektorových inštrukcií (SIMD) trvala inferencia jednej matice keprstrálnych koeficientov, prislúchajúcej jednej impulznej udalosti, v priemere len 32 milisekúnd. Tento výkon jednoznačne potvrdzuje realizovateľnosť a vhodnosť nasadenia systému pre detekciu v reálnom čase na prenosnej mikroelektronike.

Najvýznamnejším zistením experimentálnej časti bol paradoxný vplyv zníženia číselnej presnosti. Prechod z plnej výpočtovej presnosti (`float32`) na osobnom počítači do kvantizovaného formátu (`int8`) na mikrokontroléri ESP32-S3 nevedol k degradácii klasifikačnej úspešnosti. Naopak, tento proces zafungoval ako filter voči aditívnemu šumu, vďaka čomu sa výsledná robustnosť systému (reprezentovaná metrikou MCC) zlepšila. Validácia tohto javu prostredníctvom dodatočnej kvantizácie modelu priamo na PC experimentálne potvrdila, že stratové „zaokrúhľovanie“ hodnôt skutočne zlepšuje klasifikáciu.

Otvoreným predmetom pre ďalší výskum zostáva tzv. hardvérovo špecifická divergencia výpočtov. Ukázalo sa totiž, že kvantizovaný `int8` model bežiaci na platforme PC dosahoval o niečo horšie výsledky (vyššiu mieru falošných poplachov) než identický model na mikrokontroléri ESP32-S3. Najpravdepodobnejšou príčinou tohto javu sú rozdiely na úrovni hardvérovej implementácie. Vektorové inštrukcie jadra Xtensa pri operáciách maticového násobenia a akumulácie (MAC) zrejme využívajú odlišné pravidlá pre vnútorné zaokrúhľovanie medzivýsledkov v porovnaní s architektúrou x86, čo v prípade akustického detektora pôsobilo ako dodatočná vrstva šumovej filtrácie.

9.1 Obmedzenia navrhnutého riešenia

Napriek úspešnému splneniu stanovených cieľov vykazuje navrhnutý systém určité obmedzenia z hľadiska jeho priamej využiteľnosti v reálnej praxi. Prvým limitujúcim faktorom je samotný dataset. Ten pozostáva z relatívne malého počtu vzoriek, pričom všetky nahrávky boli zhotovené v kontrolovanom prostredí strelnice za akusticky ideálnych podmienok. Tieto dáta tak nemusia dostatočne verne reprezentovať komplexnú akustickú situáciu na reálnom bojisku alebo v členitom mestskom prostredí. Aj keď bola odolnosť modelu voči rušeniu extenzívne testovaná pomocou syntetickej injekcie aditívneho šumu, fyzické testovanie zariadenia priamo v teréne zatiaľ nebolo zrealizované.

Druhým významným obmedzením je špecializácia klasifikátora. Keďže pozitívna trieda („gunshot“) bola vytvorená výhradne na základe akustických prejavov húfnice vz. 77 DANA, schopnosť modelu generalizovať detekciu aj na iné typy delostreleckých systémov (napríklad mínomety alebo raketomety) zostáva bez dodatočného tréningu a rozšírenia datasetu neoverená.

9.2 Možnosti ďalšieho rozvoja

Predložená práca tvorí stabilný základ pre ďalší výskum a vývoj v oblasti inteligentných akustických senzorov. Existuje niekoľko smerov, ktorými by sa dalo zariadenie a celý systém v budúcnosti rozširovať:

- **Autonómny prenosný detekčný systém:** Rozšírením hardvéru o kvalitný externý mikrofón (napr. cez rozhranie I2S) by bolo možné signál spracovávať nepretržite priamo na *embedded* zariadení. Systém by tak fungoval úplne nezávisle a v reálnom čase by dokázal upozorniť na blížiacu sa delostreleckú hrozbu bez nutnosti pripojenia k PC.
- **Multiklasifikácia a generalizácia modelu:** Zväčšením datasetu o nahrávky iných zbraňových systémov a adekvátnou úpravou architektúry neurónovej siete by bolo možné prejsť od súčasnej binárnej klasifikácie k viactriednej. Zariadenie by tak dokázalo nielen detegovať impulznú udalosť, ale aj presne klasifikovať konkrétny typ zbrane.

Výsledky tejto práce celkovo preukazujú, že presun výpočtovo náročných algoritmov strojového učenia a spracovania signálov priamo na úroveň nízkonákladových mikrokontrolérov (Edge AI) je nielen možný, ale z hľadiska vývoja moderných autonómnych senzorov aj vysoko perspektívny.

Kapitola 10

Záver

Cieľom predloženej diplomovej práce bolo navrhnuť, implementovať a otestovať ucelený systém pre akustickú detekciu a klasifikáciu delostreleckej strelby s dôrazom na optimalizáciu pre koncové zariadenia (Edge AI). Na základe dosiahnutých výsledkov a zrealizovaných experimentov možno konštatovať, že **stanovené ciele práce boli v plnom rozsahu splnené**.

Práca komplexne pokrýva celý reťazec spracovania signálu. Vstupom boli reálne audionahrávky výstrelů z hůfnice vz. 77 DANA získané vo vojenskom výcvikovom priestore Doupov. Tieto súvislé záznamy boli algoritmicky segmentované na jednotlivé impulzné udalosti, z ktorých boli extrahované akustické odtlačky vo forme matíc Mel-frekvenčných kepstrálnych koeficientov (MFCC). Takto pripravené dáta, doplnené o negatívnu triedu bežných environmentálnych ruchov, slúžili ako vstup pre konvolučnú neurónovú sieť (CNN). Problém výraznej asymetrie datasetu bol úspešne vyriešený implementáciou metódy váženia tried (*Class Weighting*).

Najvýznamnejším prínosom práce je prenos natrénovaného modelu na platformu mikrokontroléra ESP32-S3 a následná analýza jeho správania v zašumenom prostredí. Model bol pre potreby vnoreného systému podrobený 8-bitovej celočíselnej kvantizácii (`int8`) s využitím knižnice TensorFlow Lite Micro. Evaluácia potvrdila, že táto optimalizácia nielen znížila hardvérové nároky, ale paradoxne zvýšila robustnosť klasifikácie pôsobením nelineárnej filtrácie šumu.

Navrhnutý a otestovaný systém dosahuje pozoruhodné výsledky a predstavuje stabilný základ pre ďalší výskum a vývoj, ktorého ďalším cieľom by mohla byť implementácia plne autonómneho detekčného zariadenia pracujúceho v reálnom čase.



Literatúra

- [1] D. Adamy, EW 101: A First Course in Electronic Warfare. Norwood, MA, USA: Artech House, 2001.
- [2] M. A. Richards, J. A. Scheer, and W. A. Holm, Principles of Modern Radar: Basic Principles. Raleigh, NC, USA: SciTech Publishing, 2010.
- [3] J. Svatos and J. Holub, „Impulse Acoustic Event Detection, Classification, and Localization System“, IEEE Transactions on Instrumentation and Measurement, vol. 72, Art. no. 6501515, Mar. 2023, doi: 10.1109/TIM.2023.3252631.
- [4] J. Svatos and J. Holub, „Cepstral coefficients effectiveness for gunshot classifying“, Measurement Science and Technology, vol. 35, no. 7, Art. no. 076122, Apr. 2024, doi: 10.1088/1361-6501/ad3c5d.
- [5] Jakub Svatoš - Habilitation Lecture. *Simple Acoustic Detector*. [Pdf]. 2025.
- [6] S. Cao, X. Chen, X. Zhang, and X. Chen, „Effective audio signal arrival time detection algorithm for realization of robust acoustic indoor positioning“ IEEE Trans. Instrum. Meas., vol. 69, no. 10, pp. 7341–7352, Oct. 2020, doi: 10.1109/TIM.2020.2981985.
- [7] Jakub Svatos, Jan Holub, Jan Belak, „System for an acoustic detection, localisation and classification“, Acta IMEKO, vol. 10, no. 2, article 10, June 2021, identifier: IMEKO-ACTA-10 (2021)-02-10
- [8] R. C. Maher, „Acoustical characterization of gunshots“, in 2007 IEEE Workshop on Signal Processing Applications for Public Security and Forensics, Washington, DC, USA, 2007, pp. 1-5, doi: 10.1109/S-PAPSF.2007.384077.
- [9] K. Molnár, Á. Lédeczi, L. Sujbert, and G. Péceli, „Muzzle blast detection via short time Fourier transform“, in Proc. 12th PhD Mini-Symposium, Budapest, Hungary, 2005, pp. 16-19.
- [10] R. C. Maher, „Modeling and Signal Processing of Acoustic Gunshot Recordings“, 2006 IEEE 12th Digital Signal Processing Workshop & 4th

- IEEE Signal Processing Education Workshop, Teton National Park, WY, USA, 2006, pp. 257-261, doi: 10.1109/DSPWS.2006.265386.
- [11] B. M. Sadler, L. C. Sadler and T. Pham, „Optimal and robust shockwave detection and estimation,“ in *1997 IEEE International Conference on Acoustics, Speech, and Signal Processing*, Munich, Germany, Apr. 1997, vol. 3, pp. 1889–1892, doi: 10.1109/ICASSP.1997.598908.
- [12] B. Ayoub, K. Jamal, and Z. Arsalane, „Gammatone frequency cepstral coefficients for speaker identification over VoIP networks,“ in *Proc. Int. Conf. Inf. Technol. Org. Develop. (IT4OD)*, Mar. 2016, pp. 1–5, doi: 10.1109/IT4OD.2016.7479293.
- [13] X. Valero and F. Alias, „Gammatone cepstral coefficients: Biologically inspired features for non-speech audio classification,“ *IEEE Trans. Multimedia*, vol. 14, no. 6, pp. 1684–1689, Dec. 2012, doi: 10.1109/TMM.2012.2199972.
- [14] P. Naz, J. Bouguereau, A. Lemer a F. Ywanne, „Acoustic detection and localization of artillery guns,“ in *Unattended Ground Sensor Technologies and Applications V*, vol. 5090, pp. 82-93, International Society for Optics and Photonics, 2003.
- [15] F. Rosenblatt, „The perceptron: A probabilistic model for information storage and organization in the brain,“ *Psychol. Rev.*, vol. 65, no. 6, 1958, Art. no. 386.
- [16] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, „Learning representations by back-propagating errors,“ *Nature*, vol. 323, no. 6088, 1986, Art. no. 533.
- [17] A. Krizhevsky, I. Sutskever, and G. E. Hinton, „Imagenet classification with deep convolutional neural networks,“ in *Proc. 25th Int. Conf. Neural Inf. Process. Syst.*, 2012, pp. 1097–1105.
- [18] H. Purwins, B. Li, T. Virtanen, J. Schlüter, S. -Y. Chang and T. Sainath, "Deep Learning for Audio Signal Processing, in *IEEE Journal of Selected Topics in Signal Processing*, vol. 13, no. 2, pp. 206-219, May 2019, doi: 10.1109/JSTSP.2019.2908700.
- [19] J. Schröder et al., „Classifier Architectures for Acoustic Scenes and Events: Implications for DNNs, TDNNs, and Perceptual Features from DCASE 2016,“ *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 25, no. 10, pp. 1953-1964, Oct. 2017, doi: 10.1109/TASLP.2017.2736746.
- [20] A. Morehead, L. Ogden, G. Magee, R. Hosler, B. White a G. Mohler, „Low Cost Gunshot Detection using Deep Learning on the Raspberry Pi,“ in *2019 IEEE International Conference on Big Data (Big Data)*, 2019, pp. 3038–3044, doi: 10.1109/BigData47090.2019.9006456

- [21] D. Kale, G. Ganjre and R. Udani, „A Proposed Real-Time FPGA System Using MFCC Features for Acoustic Anti-Poaching Monitoring“, 2026 International Conference on Communication, Computing and Emerging Technologies (IC3ET), Vasai, India, 2026, pp. 215-220, doi: 10.1109/IC3ET64989.2026.11467226.
- [22] S. Hershey et al., „CNN architectures for large-scale audio classification“, in 2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), New Orleans, LA, USA, 2017, pp. 131-135, doi: 10.1109/ICASSP.2017.7952132.
- [23] K. J. Piczak, „Environmental sound classification with convolutional neural networks“, 2015 IEEE 25th International Workshop on Machine Learning for Signal Processing (MLSP), Boston, MA, USA, 2015, pp. 1-6, doi: 10.1109/MLSP.2015.7324337.
- [24] F. Chollet, Deep Learning with Python, 2nd ed. Shelter Island, NY, USA: Manning Publications, 2021.
- [25] K. Simonyan and A. Zisserman, „Very deep convolutional networks for large-scale image recognition“, in 3rd International Conference on Learning Representations (ICLR), San Diego, CA, USA, 2015, doi: 10.48550/arXiv.1409.1556
- [26] A. Krizhevsky, I. Sutskever, and G. E. Hinton, „ImageNet classification with deep convolutional neural networks“, Communications of the ACM, vol. 60, no. 6, pp. 84–90, May 2017, doi: 10.1145/3065386.
- [27] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, „Dropout: A simple way to prevent neural networks from overfitting“, The Journal of Machine Learning Research, vol. 15, no. 1, pp. 1929–1958, 2014.
- [28] I. Goodfellow, Y. Bengio, and A. Courville, Deep Learning. Cambridge, MA, USA: MIT Press, 2016. (Kapitola 6.2.2.2: Sigmoid Units for Bernoulli Output Distributions).
- [29] D. P. Kingma and J. Ba, „Adam: A method for stochastic optimization“, in 3rd International Conference on Learning Representations (ICLR), San Diego, CA, USA, 2015, doi: 10.48550/arXiv.1412.6980.
- [30] D. S. Park et al., „SpecAugment: A Simple Data Augmentation Method for Automatic Speech Recognition“, in Interspeech 2019, Graz, Austria, 2019, pp. 2613–2617.
- [31] J. G. Proakis and M. Salehi, Digital Communications, 5th ed. New York, NY, USA: McGraw-Hill, 2008.
- [32] C. M. Bishop, Pattern Recognition and Machine Learning. New York, NY, USA: Springer, 2006.

- [33] H. He and E. A. Garcia, „Learning from Imbalanced Data,“ *IEEE Transactions on Knowledge and Data Engineering*, vol. 21, no. 9, pp. 1263–1284, Sept. 2009, doi: 10.1109/TKDE.2008.239.
- [34] D. M. W. Powers, „Evaluation: from precision, recall and F-measure to ROC, informedness, markedness and correlation,“ *Journal of Machine Learning Technologies*, vol. 2, no. 1, pp. 37–63, 2011.
- [35] D. Chicco and G. Jurman, "The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation," *BMC Genomics*, vol. 21, no. 1, p. 6, Jan. 2020, doi: 10.1186/s12864-019-6413-7.
- [36] J. Davis and M. Goadrich, „The relationship between Precision-Recall and ROC curves,“ in *Proceedings of the 23rd International Conference on Machine Learning (ICML)*, Pittsburgh, PA, USA, 2006, pp. 233–240, doi: 10.1145/1143844.1143874.
- [37] C. Antonopoulos et al., „Reducing the Power Consumption of Edge Devices Supporting Ambient Intelligence Applications,“ *Information*, vol. 15, no. 3, p. 161, Mar. 2024, doi: 10.3390/info15030161.
- [38] Espressif Systems, ESP32-S3 Series Datasheet. Shanghai, China: Espressif Systems, 2024. [Online]. Dostupné: <https://www.espressif.com/>
- [39] Espressif Systems, „ESP-NN: Optimized Neural Network Library,“ GitHub repository, 2024. [Online]. Dostupné: <https://github.com/espressif/esp-nn>
- [40] B. Jacob et al., „Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference,“ in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Salt Lake City, UT, USA, 2018, pp. 2704–2713.
- [41] Espressif Systems, ESP-IDF Programming Guide, 2024. [Online]. Dostupné: <https://docs.espressif.com/projects/esp-idf/>
- [42] R. David et al., „TensorFlow Lite Micro: Embedded Machine Learning for TinyML Systems,“ in *Proceedings of Machine Learning and Systems (MLSys)*, vol. 3, pp. 800–811, 2021.
- [43] J. Salamon and J. P. Bello, „Deep Convolutional Neural Networks and Data Augmentation for Environmental Sound Classification,“ *IEEE Signal Processing Letters*, vol. 24, no. 3, pp. 279–283, 2017.
- [44] J. Lin, C. Gan, and S. Han, „Defensive Quantization: When Efficiency Meets Robustness,“ in *7th International Conference on Learning Representations (ICLR)*, New Orleans, LA, USA, 2019.

Zoznam použitých skratiek

- **ADC** - Analog-to-Digital Converter (Analógovo-digitálny prevodník).
- **AWGN** - Additive White Gaussian Noise (Aditívny biely Gaussov šum).
- **CFAR** - Constant False Alarm Rate (Konštantná miera falošných poplachov).
- **CNN** - Convolutional Neural Network (Konvolučná neurónová sieť).
- **dB** - Decibel (jednotka hladiny intenzity zvuku).
- **DCT** - Discrete Cosine Transform (Diskrétna kosínová transformácia).
- E_m - Energy (Energia v m-tom Melovom pásme).
- **FFT** - Fast Fourier Transform (Rýchla Fourierova transformácia).
- **FN** - False Negative (Falošne negatívna klasifikácia).
- **FP** - False Positive (Falošne pozitívna klasifikácia).
- **Hz** - Hertz (jednotka frekvencie).
- **Im** - Imaginárna časť signálu.
- **kB** - Kilobyte (Kilobajt).
- **MCC** - Matthews Correlation Coefficient (Matthewsov korelačný koeficient).
- **mel** - Jednotka výšky zvuku na Melovej škále.
- **MFCC** - Mel-Frequency Cepstral Coefficients (Mel-frekvenčné keprálne koeficienty).
- **ms** - Milisekunda (jednotka času).
- **NFFT** - Number of FFT bins (Počet bodov Fourierovej transformácie).
- **RAM** - Random Access Memory (Pamäť s priamym prístupom / Operačná pamäť).

- **Re** - Reálna časť signálu.
- **ReLU** - Rectified Linear Unit (Usmernená lineárna jednotka).
- **SIMD** - Single Instruction, Multiple Data (Jedna inštrukcia, viacero dát).
- **SNR** - Signal-to-Noise Ratio (Odstup signálu od šumu).
- **STFT** - Short-Time Fourier Transform (Krátkodobá Fourierova transformácia).
- **TDOA** - Time Difference of Arrival (Časový rozdiel príchodu signálu).
- **TN** - True Negative (Správne negatívna klasifikácia).
- **TP** - True Positive (Správne pozitívna klasifikácia).
- **UART** - Universal Asynchronous Receiver-Transmitter (Univerzálny asynchrónny prijímač a vysielateľ).